



乙醇偶合制备 C4 烯烃的统计分析与建模

崔恒建, 王冠鹏, 郑志伟

(首都师范大学 数学科学学院, 北京 100048)

摘要: 根据 2021 年“高教社杯”全国大学生数学建模竞赛 B 题所给的数据, 对乙醇转化率、C4 烯烃的选择性进行了探索性数据分析, 分析了催化剂组合与温度对乙醇转化率、C4 烯烃的选择性的影响, 并采用多元线性回归模型和 Logit 变换回归模型对实验数据进行统计分析和探究, 给出了“乙醇偶合制备 C4 烯烃”赛题的具体可行性解法及对参赛论文的简评.

关键词: 乙醇转化率; C4 烯烃选择性; C4 烯烃转化率; Logit 回归模型; 变量筛选

中图分类号: O212.4

文献标志码: A

文章编号: 2095-3070(2022)01-0054-10

DOI: 10.19943/j.2095-3070.jmmia.2022.01.07

1 问题与背景

C4 烯烃广泛应用于化工产品及医药的生产, 乙醇是制备 C4 烯烃的原料. 在制备过程中, 催化剂组合(即 Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度的组合)、温度对 C4 烯烃的选择性和 C4 烯烃收率将产生影响^[1]. 通过对催化剂组合设计, 探索乙醇催化偶合制备 C4 烯烃的工艺条件具有重要的意义和价值.

某化工实验室研究以乙醇为平台化合物, 针对不同催化剂做了一系列实验, 结果如题目的附件 1、附件 2 所示. 请根据实验结果所提供的数据, 通过数学建模完成下列问题:

问题 1 对附件 1 中每种催化剂组合, 分别研究乙醇转化率、C4 烯烃的选择性与温度的关系, 并对附件 2 中给定的催化剂且温度为 350 °C 时在一次实验不同时间的测试结果进行分析.

问题 2 探讨不同催化剂组合和温度对乙醇转化率以及 C4 烯烃选择性大小的影响.

问题 3 如何选择催化剂组合与温度, 使得在相同实验条件下 C4 烯烃收率尽可能高. 若使温度低于 350 °C, 又如何选择催化剂组合与温度, 使得 C4 烯烃收率尽可能高.

问题 4 如果允许再增加 5 次实验, 你认为如何安排, 并给出详细理由.

2 数据处理与探索性数据分析

本题目是探究分析在制备过程中, 催化剂组合、温度对 C4 烯烃的选择性和 C4 烯烃收率的影响. 主要考察学生对实验数据的认识处理以及数据对模型影响的分析能力, 包括数据处理和可视化、相关性分析、检验、多元非线性回归分析、实验设计、误差分析以及影响因素的分析能力. 首先对实验数据进行探索性分析.

收稿日期: 2022-01-25

基金项目: 国家自然科学基金重点项目(12031016); 国家自然科学基金项目(11971324, 11471223); 北京市科技创新平台建设项目(19530050181)

通讯作者: 崔恒建, E-mail: hjcui@bnu.edu.cn

引用格式: 崔恒建, 王冠鹏, 郑志伟. 乙醇偶合制备 C4 烯烃的统计分析与建模[J]. 数学建模及其应用, 2022, 11(1): 54-63.

CUI H J, WANG G P, ZHENG ZH W. Statistical analysis and modeling of ethanol coupling to prepare C4 olefins(in Chinese)[J]. Mathematical Modeling and Its Applications, 2022, 11(1): 54-63.

2.1 样本剔除

A11 催化剂组合使用石英砂而非 HAP，在确认其为干扰样本之后，故决定剔除 A11 的 5 组样本.

2.2 数据变换

从剩余的 20 种催化剂组合信息中提取 3 个主要因素：Co 负载量，Co/SiO₂ 和 HAP 装料比，乙醇浓度. 对其中变量进行命名，如表 1 所示.

表 1 符号及说明表

符号	说明	符号	说明
Y_1	乙醇转化率	X_3	乙醇浓度
Y_2	C4 烯烃选择性	X_4	温度
X_1	Co 负载量	$Y_3=Y_1Y_2$	C4 烯烃收率
X_2	Co/SiO ₂ 和 HAP 的装料比		

考虑到乙醇转化率以及 C4 烯烃选择性为百分数形式，故通过 Logit 变换将它们以及乘积(C4 烯烃收率)这 3 类百分数投射到整个实数轴上，这样做充分利用到了线性模型中所有值，同时不改变自变量对因变量的影响. 所以，对上述变量 Y_1 , Y_2 和 $\sqrt{Y_1Y_2}$ 作 Logit 变换，记新变量为：

$$\begin{cases} y_1 = \log(Y_1/(100-Y_1)), \\ y_2 = \log(Y_2/(100-Y_2)), \\ y_3 = \log(\sqrt{Y_1Y_2}/(100-\sqrt{Y_1Y_2})). \end{cases} \tag{1}$$

2.3 相关性分析

利用分布散点矩阵图对变量进行可视化处理，如图 1 所示. 矩阵图对角线显示各变量的分布，可以发现 C4 烯烃收率、乙醇转化率和 C4 烯烃选择性大致呈现正态分布趋势. 矩阵图对角线下方为变量间的散点图分布，对角线上方则是对应的相关系数，通过散点图及相关系数可以发现温度对 C4 烯烃收率、乙醇转化率和 C4 烯烃选择性有着显著正影响.




图 1 变量分布散点矩阵图

2.4 对问题 1 的探讨

为了探究温度对乙醇转化率和 C4 烯烃选择性的影响,对催化剂组合的影响进行控制,尝试多种拟合模型,选择较优的拟合函数,并得到乙醇转化率和 C4 烯烃的选择性与温度的函数关系.通过观察并确定所要拟合的模型曲线形式,优化计算出模型拟合值,如:线性、二次、指数、Logit 变换线性建模,参数估计等.我们认为采用 Logit 变换一次或二次模型是较好的选择,这样所用参数少而显著,平均 R^2 较高.以 A5 为例,用 Logit 变换二次拟合,乙醇转化率和 C4 烯烃的选择性的 R^2 分别为 0.985 5 和 0.967 7,表现显著.拟合效果见图 2.利用 20 种催化剂组合下的结果分别构建折线图,前 13 个表示 A1—A10 和 A12—A13;后 7 个表示 B1—B7 温度跟乙醇转化率和 C4 烯烃选择性的关系.用 Logit 二次曲线拟合与温度之间的关系,其中,Logit 回归模型为:

$$\begin{cases} \log(Y_1/(100-Y_1)) = \beta_{40} + \beta_{41}X_4 + \beta_{42}X_4^2 + \varepsilon_1, \\ \log(Y_2/(100-Y_2)) = \gamma_{40} + \gamma_{41}X_4 + \gamma_{42}X_4^2 + \varepsilon_2. \end{cases} \quad (2)$$




图 2 乙醇转化率与 C4 烯烃选择性曲线图

通过线性回归估计出各自的相关系数,得到拟合的曲线为:

$$\hat{Y}_1 = \frac{\exp(\hat{\beta}_{40} + \hat{\beta}_{41}X_4 + \hat{\beta}_{42}X_4^2)}{1 + \exp(\hat{\beta}_{40} + \hat{\beta}_{41}X_4 + \hat{\beta}_{42}X_4^2)}; \hat{Y}_2 = \frac{\exp(\hat{\gamma}_{40} + \hat{\gamma}_{41}X_4 + \hat{\gamma}_{42}X_4^2)}{1 + \exp(\hat{\gamma}_{40} + \hat{\gamma}_{41}X_4 + \hat{\gamma}_{42}X_4^2)}.$$

采用决定系数 R^2 反应因变量的全部变异性能通过回归关系被自变量解释的比例. 表 2 将展示剔除催化剂组合 A11 以后(A1—A10, A12—A14, B1—B7), 20 种催化剂组合温度跟乙醇转化率和 C4 烯烃选择性的 R^2 . 为了有利于后面建模, 对不同催化剂作用下乙醇转化率和 C4 烯烃的选择性与温度进行相关分析, 并说明其显著性.

表 2 乙醇转化率、C4 烯烃选择性与温度的拟合 R^2 表

平均 $R^2=0.993\ 8$										
	A1	A2	A3	A4	A5	A6	A7	A8	A9	A10
Y_1	0.987 0	0.999 7	0.975 8	0.994 3	0.985 5	0.984 8	0.998 9	0.998 3	1.000 0	0.995 5
	A12	A13	A14	B1	B2	B3	B4	B5	B6	B7
	0.998 9	0.999 5	0.996 7	0.998 7	0.998 8	0.992 3	0.995 9	0.998 2	0.980 5	0.997 2
平均 $R^2=0.975\ 1$										
	A1	A2	A3	A4	A5	A6	A7	A8	A9	A10
Y_2	0.920 9	0.969 9	0.986 8	0.945 9	0.967 4	0.930 9	0.994 4	0.999 1	0.999 9	0.986 8
	A12	A13	A14	B1	B2	B3	B4	B5	B6	B7
	0.998 2	0.993 9	0.992 9	0.995 8	0.996 8	0.966 6	0.908 1	0.9914	0.9596	0.996 8

分析各个因变量与温度间的关联分析,非线性影响、显著性检验等. 当使用灰色关联度分析(分辨系数 0.5), 例如: 催化剂组合中 A2、A4 和 A5 的灰色关联度分析, 灰色关联度分析结果见表 3.

表 3 灰色关联度结果表

	A2	A4	A5
$\gamma(X_1, Y_1)$	0.581 6	0.624 8	0.622 4
$\gamma(X_1, Y_2)$	0.960 7	0.604 8	0.930 1

利用附件 2 的数据分别构建 350 °C 时某一催化剂组合下乙醇转化率和 C4 烯烃的选择性与时间的稳定性分析. 其中可用最值差值法或方差分析来判断 Logit 变换或均值模型残差的方差是否减少. 本文仍然采用公式(1)的 Logit 二次变换和一次变换来探索拟合效果.

首先通过表 4 和表 5 来看回归变量的重要性, 通过 t 检验看回归系数是否显著. 表 4 和表 5 分别是乙醇转化率和 C4 烯烃选择性跟时间的 Logit 二次(一次)变换模型的回归系数表.

表 4 乙醇转化率跟时间的 Logit 二次回归系数表

	回归系数	估计标准误差	T 值	P 值
截距项	-1.883e-01	3.435e-02	-5.484	0.005 38**
T	-4.361e-03	5.414e-04	-8.056	0.001 29**
T^2	6.960e-06	1.782e-06	3.906	0.017 45*

显著程度: 0 '***'; 0.001 '**'; 0.01 '*'; 0.05 '.'; 0.1 ' ' 1

表 5 C4 烯烃选择性跟时间的 Logit 一次回归系数表

	回归系数	估计标准误差	T 值	P 值
截距项	-0.465 301 3	0.041 334 0	-11.257	9.66e-05***
T	0.000 116 6	0.000 235 9	0.494	0.642

显著程度: 0 '***'; 0.001 '**'; 0.01 '*'; 0.05 '.'; 0.1 ' ' 1

用 Logit 二次回归模型来拟合乙醇转化率跟时间的关系, 多重 $R^2 = 0.988\ 3$ 说明拟合效果非常

好, 并且表 4 也容易发现温度的一次项和二次项 P 值小于 0.01, 因此用 Logit 二次回归模型来拟合乙醇转化率跟时间非常合理. Logit 一次回归模型来拟合乙醇转化率跟时间, 多重 $R^2 = 0.0466$, 说明拟合效果非常好. 由表 5 也容易发现假设“温度的一次项 P 值小于 0.01, 二次项系数的 P 值大于 0.05”不能通过显著性检验. 因此用 Logit 一次回归模型来拟合乙醇转化率跟时间的时候, 只有截距项是显著的. 乙醇转化率和 C4 烯烃选择性与时间的稳定性分析结果如图 3 所示.




图 3 乙醇转化率和 C4 烯烃选择性与时间的稳定性分析结果图

由图 3(a)可以看出, 在给定的催化剂组合和温度下, 乙醇转化率随着时间的增长呈现指数衰减趋势, 并且随着时间变化稳定在 30%; 而图 3(b)则显示出 C4 烯烃选择性随时间的变化在 39% (样本均值) 左右不断波动, 并且随着时间变化稳定在 39%.

3 多元 Logit 回归模型的建立

本节针对问题 2, 探究不同乙醇浓度、Co 的负载量、装料比以及温度对乙醇转化率和 C4 烯烃选择性的影响程度. 由于乙醇转化率和 C4 烯烃选择性数据均为百分数, 类似于第 1 节的处理, 通常进行 Logit 等变换, 再建立多元回归模型来进行比较(多因素方差分析), 以确定重要因素.

3.1 多元线性回归模型

首先介绍大家熟悉的多元线性模型. 用不同乙醇浓度、Co 的负载量、装料比变量和温度 4 个变量, 对乙醇转化率和 C4 烯烃选择性分别建立多元线性回归模型. 当收集到组观测数据 $(y_i, x_{i1}, x_{i2}, \dots, x_{i4}) (i=1, 2, \dots, n)$, 有如下多元线性回归模型:

$$\begin{cases} y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_4 x_{i4} + \epsilon_i, \\ \epsilon_i \text{ iid. } \sim N(0, \sigma^2), i=1, 2, \dots, n, \end{cases} \quad (3)$$

对以上模型, 回归系数 $\beta = (\beta_0, \beta_1, \dots, \beta_{11})'$ 的估计通常为最小二乘估计, 其表达式为:

$$\hat{\beta} = (C'C)^{-1}C'Y,$$

其中, $C = (I_n : X)$, 并满足性质 $E(\hat{\beta}) = \beta$, $\text{Cov}(\hat{\beta}) = (C'C)^{-1}\sigma^2$. 残差和标准化(也称标准化)残差分别为:

$$r_i = y_i - X_i^T \hat{\beta}, r_i^* = r_i / s(r), i=1, 2, \dots, n,$$

其中, $s(r)$ 为残差向量的标准差. 复相关系数(决定系数)和调整的复相关系数分别为:

$$R^2 = \frac{\text{SSR}}{\text{SST}} = 1 - \frac{\text{SSE}}{\text{SST}}, R^{*2} = 1 - \frac{\text{SSE}}{n-p-1} / \frac{\text{SST}}{n-1},$$

其中, $\text{SST} = \sum_{i=1}^n (y_i - \bar{y})^2$, $\text{SSE} = \sum_{i=1}^n r_i^2$. 对以上模型中第 j 个回归系数做显著性检验, 即

$$H_0: \beta_j = 0 \leftrightarrow H_1: \beta_j \neq 0,$$

所用统计量通常为 $T = \frac{(C'C)^{1/2} \hat{\beta}_j}{\sqrt{n \text{MSE} / (n-p-1)}}$.

在零假设 H_0 成立时, T 近似服从自由度为 $n-p-1$ 的 t 分布, 所以当 $|T| \geq t_{\alpha/2}(n-p-1)$ 时, 拒绝

零假设, 其中, α 是检验的显著性水平, 实际应用中, 可根据情况设为 $\alpha=0.05$ 或 0.01 . 详细应用过程可参考文献[2-5]. 当使用全因素方差分析, 其中方差分析表中使用 F-检验, 显著水平 0.05 . 通过分析表明: 温度和乙醇浓度两个因素同时对 Y_1 和 Y_2 产生显著影响, 并且温度比乙醇浓度产生的影响要大一些.

第 1 节在单变量影响的探索性分析中, 通过可视化及简单线性回归得出了温度对乙醇转化率和 C4 烯烃选择性具有显著正影响, 同时观察到不同催化剂组合的影响存在一定差异性. 在本节中, 进一步探究催化剂组合主要因素(Co 负载量、装料比和乙醇浓度)以及温度这 4 个变量对乙醇转化率和 C4 烯烃选择性所产生的联合影响下各自的影响程度比较. 从图 1 中 4 个自变量的分布图来看, 可以发现变量的量纲存在巨大差异, 故为了保证影响分析的可靠性, 需要通过 Z-score 标准化处理剔除量纲带来的影响, 即

$$x_i = \frac{X_i - \mu_i}{\sigma_i},$$

其中, μ_i 和 σ_i 分别为变量 X_i 的均值与标准差, 这里使用样本均值与样本标准差代替. 对于变量影响分析, 这里采用的是方差分析的思想, 利用构建多元线性回归模型并计算比较各自变量对因变量变异的贡献来刻画自变量对因变量的影响程度, 即:

$$SST = SSR_1 + SSR_2 + SSR_3 + SSR_4 + SSE,$$

其中, SSR_1 、 SSR_2 、 SSR_3 和 SSR_4 分别表示 Co 负载量、装料比、乙醇浓度以及温度在多元线性回归模型中的回归平方和. 同时, 可以计算出 F 统计在原假设下 $F_i = \frac{SSR_i/1}{SSE/104}$ 服从 $F(1, 104)$ 分布, 来检验自变量对因变量影响的显著性.

3.2 Logit 变换回归模型

Logit 变换一次回归模型的数学模型表达为:

$$\begin{cases} y_1 = \ln\left(\frac{Y_1}{100 - Y_1}\right) = \beta_0 + \sum_{i=1}^4 \beta_i X_i + \epsilon_1, \\ y_2 = \ln\left(\frac{Y_2}{100 - Y_2}\right) = \gamma_0 + \sum_{i=1}^4 \gamma_i X_i + \epsilon_2, \end{cases} \quad (4)$$

其中: Y_1 是乙醇转化率, Y_2 是 C4 烯烃选择性; X_1 、 X_2 、 X_3 和 X_4 分别是 Co 负载量、Co/SiO₂ 和 HAP 的装料比、乙醇浓度和温度的变量名, 具体推导和理论分析可见文献[6]. 下面使用 Logit 线性回归模型, 分别关于 Co 负载量、Co/SiO₂ 和 HAP 的装料比、乙醇浓度和温度, 跟乙醇转化率和 C4 烯烃选择性进行方差分析, 其方差分析表见表 6.

表 6 方差分析表

	Df	Sum Sq	Mean Sq	F value	P-value
Y ₁ : 乙醇转化率					
X ₁	1	0.03	0.03	0.039	0.843
X ₂	1	2.54	2.54	3.258	0.074
X ₃	1	44.06	44.06	56.609	1.98e-11 ***
X ₄	1	182.48	182.48	234.464	<2e-16 ***
残差	104	80.94	0.78		
Y ₂ : C4 烯烃选择性					
X ₁	1	8.31	8.31	19.846	2.12e-5 ***
X ₂	1	0.74	0.74	1.772	0.074
X ₃	1	0.71	0.71	1.684	0.197
X ₄	1	63.87	63.87	152.523	<2e-16 ***
残差	104	43.55	0.42		

续表 6

	Df	Sum Sq	Mean Sq	F value	P-value
Y_3 : C4 烯烃收率					
X_1	1	8.31	8.31	19.846	2.12e-5***
X_2	1	0.74	0.74	1.772	0.074
X_3	1	0.71	0.71	1.684	0.197
X_4	1	63.87	63.87	152.523	< 2e-16***
残差	104	41.64	0.40		

通过单因素方差分析, 得到对 y_1 的影响因素依次为:

温度 > 乙醇浓度 > 装料比 > Co 的负载量,

其中, $R^2=0.740$, 回归系数 $\hat{\beta}_1=(-1.830, 0.087, -0.125, -0.597, 1.300)$. 类似地, 对 y_2 的影响因素依次为:

温度 > Co 的负载量 > 装料比 > 乙醇浓度,

其中, $R^2=0.692$, 回归系数 $\hat{\beta}_2=(-1.908, 0.098, -0.089, 0.767, -0.78)$.

4 带交互变量的 Logit 模型及变量筛选

本部分对问题 3 进行探讨. 首先探讨 Co 负载量、Co/SiO₂ 和 HAP 装料比、乙醇浓度、温度对乙醇转化率和 C4 烯烃的选择性的影响, 分析各个影响因素之间的交互作用, 从而建立 C4 烯烃收率与温度、装料比、Co 负载量、乙醇浓度之间的模型, 并给出 C4 烯烃收率最大时的催化剂组合. 其次, 从提高 C4 烯烃收率(C4 烯烃收率=乙醇转化率×C4 烯烃选择性)为目标, 对数据 X 进行统计标准化处理, 建立 Logit 变换二次交互回归模型.

4.1 带交互的 Logit 变换二次回归模型

在第 2 节中已经介绍了多元变量的 Logit 线性回归模型, 下面考虑加入交互项的 Logit 二次回归模型:

$$\begin{cases} y_1 = \ln\left(\frac{Y_1}{100-Y_1}\right) = \beta_0 + \sum_{i=1}^4 \beta_i X_i + \mathbf{Z}'\mathbf{B} + \varepsilon_1, \\ y_2 = \ln\left(\frac{Y_2}{100-Y_2}\right) = \gamma_0 + \sum_{i=1}^4 \gamma_i X_i + \mathbf{Z}'\mathbf{T} + \varepsilon_2, \end{cases} \quad (5)$$

其中二次交互项表达 $\mathbf{Z}' = (X_1^2, \dots, X_4^2, X_1X_2, X_1X_3, X_1X_4, X_2X_3, X_2X_4, X_3X_4)$, 二次项系数为 $\mathbf{B} = (\beta_5, \beta_6, \dots, \beta_{14})'$ 和 $\mathbf{T} = (\gamma_5, \gamma_6, \dots, \gamma_{14})'$. 当用 Logit 变换后的模型得到参数估计后, 则收率的优化数学表达式(模型)为:

$$P = \frac{Y_1 \times Y_2}{100^2} = \frac{\exp\{y_1\}}{1 + \exp\{y_1\}} \times \frac{\exp\{y_2\}}{1 + \exp\{y_2\}} = \max. \quad (6)$$

当温度小于等于 450 °C 时, 优化目标函数的约束条件为:

$$\begin{cases} (0.5 - m_1)/s_1 \leq x_1 \leq (5 - m_1)/s_1, \\ (0.5 - m_2)/s_2 \leq x_2 \leq (2 - m_2)/s_2, \\ (0.3 - m_3)/s_3 \leq x_3 \leq (2.1 - m_3)/s_3, \\ (250 - m_4)/s_4 \leq x_4 \leq (450 - m_4)/s_4. \end{cases}$$

如果要求温度小于 350 °C, 则上述优化目标条件更新为:

$$\begin{cases} (0.5 - m_1)/s_1 \leq x_1 \leq (5 - m_1)/s_1, \\ (0.5 - m_2)/s_2 \leq x_2 \leq (2 - m_2)/s_2, \\ (0.3 - m_3)/s_3 \leq x_3 \leq (2.1 - m_3)/s_3, \\ (250 - m_4)/s_4 \leq x_4 \leq (350 - m_4)/s_4. \end{cases}$$

其中, m_i 和 s_i 分别是各个变量之间的均值和方差.

在温度为 450 °C 以下的收益计算过程中, 如果直接使用 Logit 线性回归模型, 通过计算可得到收益的最大值为 0.601, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 0.739, 2.004, 0.319 和 449.6. 但如果考虑加入交互项的之后, 则需要对变量进行筛选, 以去除变量共线性等影响. 对 14 个变量, 用 ncvreg(R 包) 中的 Lasso 方法进行变量选择 (具体见文献[7-8]). 对模型 y_1 , 所选择的变量有 $X_2, X_3, X_4, X_2^2, X_3X_4$; 对模型 y_2 , 所选择的变量有 $X_3, X_4, X_1^2, X_1X_3, X_3X_4$. 注意到筛选后的重要变量也非常吻合一次 Logit 回归模型的变量的重要性, 温度变量最重要, 一定留在模型中做预测. 此时可优化计算出最大收率 $P=0.631$, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 3.168, 1.011, 0.317, 449.968.

在温度小于 350 °C 的低温时, 如果采用 Logit 线性回归模型, 通过计算得到收率的最大值 $P=0.144$, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 0.539, 1.393, 0.303, 349.802. 如果采用二次交互的回归模型, 仍然用上面筛选出来的重要变量做预测, 此时最大收率为 $P=0.266$, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 4.222, 1.886, 0.309, 349.868. 这样通过 Logit 变换后二次交互模型及其变量筛选, 获得了收率的最优值及其最优设计.

4.2 变量乘积的 Logit 回归模型

前面计算 C4 烯烃的最大收率是把 Y_1 和 Y_2 做完变换后, 再按照 C4 烯烃收率等于两者的乘积来进行建模计算的. 按照 C4 烯烃收率的定义, 还可以把 Y_1 和 Y_2 先做乘积, 把它当作一个目标变量来进行建立模型:

$$y_3 = \ln \left[\frac{\sqrt{Y_1 Y_2} / 100}{1 - \sqrt{Y_1 Y_2} / 100} \right] = \gamma_0 + \sum_{i=1}^4 \gamma_i X_i + \mathbf{Z}^T \boldsymbol{\Gamma} + \epsilon_3. \quad (7)$$

注意到上面模型中使用 $\sqrt{Y_1 Y_2}$ 而不使用 $Y_1 Y_2$ 作为新变量的原因是: 两个百分比数据相乘后是一个二次项, 所以再进行一次根号变换使得变换后的数据尽量保持原有的形状和性质. 在温度为 450 °C 以下的收率计算过程中, 对变量 $\sqrt{Y_1 Y_2}$ 使用 Logit 线性回归模型, 通过计算得到收率的最大值 $P=0.653$, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 0.771, 0.743 4, 0.301, 449.707. 如果加入交互项之后, 同样使用 Lasso 对变量进行选择, 得到对 y_3 模型 (7) 有用的变量为 X_3, X_4, X_3^2, X_1X_3 . 此时最大收率 $P=0.564$, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 4.988, 0.857, 0.310, 449.501.

在温度小于 350 °C 的低温时, 如果采用 Logit 线性回归模型, 通过计算得到收率的最大值 $P=0.147$, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 0.608, 0.517, 0.322, 349.375. 如果采用二次交互回归模型, 仍然用上面筛选出来的重要变量做预测. 此时最大收益为 $P=0.287$, 且催化剂组合 (Co 负载量, Co/SiO₂ 和 HAP 装料比, 乙醇浓度) 与温度分别为: 4.994, 0.905, 0.310, 349.615.

综上两种 Logit 变换模型, 温度控制在 450 °C 以内的条件下, 模型中是否加入交互项, 最大收率都维持在 0.60 左右; 而在 350 °C 以内的条件下, 建议使用交互变量加入模型, 这时收率最大能达到 0.26~0.29 之间.

5 新增试验样本的设计

本节探讨问题 4. 需要提出新实验设计的思路、准则或模型, 并在此基础上给出 5 次具体的实验方案, 包括催化剂组合与温度, 这里的思路、准则或模型比较多. 建议考虑试验设计中样本点空间的均匀分布准则, 其原因是在利用实验数据来建模进行分析时, 结果会更加稳定. 对此, 在原有 109 次实验基础上, 增加 5 次试验, 使得共 114 次实验数据与均匀分布尽量接近, 于是优化目标函数定义如下:

$$(x_1^*, x_2^*, x_3^*, x_4^*) = \arg \min_{(x_1, x_2, x_3, x_4) \in D} D_4(x_1, x_2, x_3, x_4), \quad (8)$$

其中:

$$D_5(x_1^*, x_2^*, x_3^*, x_4^*) = \sup_{t \in D} |F_{X \cup \{x_1, x_2, x_3, x_4\}}(t) - U_D(t)|,$$

$$D = [0.5, 5] \times [0.5, 2] \times [0.3, 2.1] \times [250, 450],$$

X 为已有的 109 次实验点集合, $F_{X \cup \{x_1, x_2, x_3, x_4\}}(t)$ 为 114 次实验数据的经验分布, $U_D(t)$ 为 D 上的均匀分布函数. 首先, 根据优化准则(7), 对 5 个新增试验点进行优化, 并采用蒙特卡洛(MC)方法^[9]进行优化计算(结果不唯一), 例如

$(x_1^*, x_2^*, x_3^*, x_4^*) = (4.616, 1.279, 1.187, 281.160)$ 、 $(4.055, 1.515, 1.200, 285.378)$ 、 $(4.290, 1.126, 1.817, 421.567)$ 、 $(1.915, 1.731, 0.774, 269.190)$ 和 $(3.313, 1.330, 1.454, 291.034)$.

其次, 利用模型(5)和(6), 把对 C4 烯烃收率进行最大化的一个最优设计作为固定点, 再加入 4 个点对准则(8)进行优化(结果不唯一), 这里列出其中一个优化结果:

$$\begin{aligned}(x_1^*, x_2^*, x_3^*, x_4^*) &= (3.168, 1.011, 0.317, 449.968); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (0.538, 0.787, 1.081, 337.908); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (2.152, 2.003, 0.986, 439.920); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (0.837, 1.658, 1.024, 258.813); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (3.875, 1.497, 1.005, 254.629).\end{aligned}$$

如果利用模型(7), 把对 C4 烯烃收率进行最大化的一个最优设计作为固定点, 再加入 4 个点对准则(8)进行优化(结果不唯一), 得到其中一个优化结果为:

$$\begin{aligned}(x_1^*, x_2^*, x_3^*, x_4^*) &= (4.988, 0.857, 0.310, 449.501); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (0.625, 0.730, 0.553, 377.624); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (4.860, 1.476, 1.945, 252.214); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (3.312, 0.493, 1.600, 285.289); \\(x_1^*, x_2^*, x_3^*, x_4^*) &= (4.560, 1.517, 1.673, 408.718).\end{aligned}$$

当然也可以考虑单变量准则进行优化, 但这样可能会失去相关关系的利用, 使得模型精度不够或不稳定, 这里不再赘述.

6 参赛论文简评

本题目属于由试验数据到数学建模, 赛题主要考核学生对实际数据特点的把握与统计模型的合理使用, 对结果表达与模型稳定性的分析. 总体情况反映了目前大学生的实际统计数据分析和培训水平, 各有特色, 罗列式的建模方法较多, 编程能力较好. 下面是赛题四问中学生建模常用的方法总结及不足之处.

第 1 问: 对试验数据的特点的观察和分析是本题建模的基础要点. 剔除 A11 的不多; 对百分比数据进行 Logit 变换再进行回归分析的学生较少. 普遍选用线性、二次、三次、指数(解方程)等曲线拟合方法, 以 R^2 为衡量标准评判. 部分使用一些高次多项式或 11 类函数直接拟合, 忽略了过拟合现象. 在相关、误差和结果稳定性方面缺少有效分析, 更多的只是描述性地给出说明.

第 2 问: 学生使用多元线性回归、主成分回归、偏最小二乘回归、单(多)因素方差分析、灰色关联分析、控制单一变量进行对比分析等方法, 也有 BP 神经网络, 决策树、RF 模型等机器学习方法. 多数学生对变量的共线性、对残差的分析考虑较少. 在学习算法写作上比较粗糙, 缺少模型检验和合理的解释. 部分学生没有明确给出解释变量的影响程度.

第 3 问: 大部分学生分别考虑到了影响因素之间的交互效应, 给出了目标函数 C4 收率的表示, 求解带约束条件的二次规划问题, 但对加入哪些交互项比较主观, 缺少分析和选择. 有相当多直接使用了神经网络、随机森林、决策树、XG-Boost 等机器学习方法来求解, 有些因求解方法或约束条件使用不当使得有些解溢出边界, 计算结果理想的不多.

第 4 问: 需要利用正交实验或均匀设计的思想, 给出补充实验的准则和 5 次具体方案. 少数几份

是按正交试验或均匀设计安排的,但计算不完整.大多数学生各有侧重,或考虑对照实验,或考虑使 C4 烯烃收率最大的实验.有的直接给出具体方案,也没有理由说明或理由不充分.

总之,对学生的数据探索分析方法以及数据的可视化方法有了一定的训练,但对数据异常值的处理能力还不够,对统计或传统机器学习方法的合理使用到具体问题中还有待于进一步学习和提高.

参考文献

- [1]吕绍沛.乙醇偶合制备丁醇及 C₄ 烯烃[D].大连:大连理工大学,2018.
- [2]高惠璇.应用多元统计分析[M].北京:北京大学出版社,2005.
- [3]David A. Freeman.统计模型-理论和实践[M].2版.吴喜之,译.北京:机械工业出版社,2014.
- [4]崔恒建.“颜色与物质浓度辨识”问题初探[J].数学建模及其应用,2018,7(1):34-42.
- [5]崔恒建,田万.空气质量数据校准的统计学习与建模[J].数学建模及其应用,2020,9(1):57-66.
- [6]Menard S.应用 logistic 回归分析[M].2版.吴晓,译.上海:人民出版社,2016.
- [7]Li R, Cui H. Variable selection via regularization, encyclopedia of environmentrics [M]. Chicester: Wiley, 2014.
- [8]王冠鹏,秦双燕,崔恒建.员工流失的影响因素分析与预测[J/OL].系统科学与数学,2022. [2021-12-02]. <https://kns.cnki.net/kcms/detail/11.2019.O1.20220223.1521.002.html>.
- [9]Reuven Y R, Dirk P K. 仿真与蒙特卡洛方法[M].2版.卫军胡,王虹,译.西安:西安交通大学出版社,2020.

Statistical Analysis and Modeling of Ethanol Coupling to Prepare C4 Olefins

CUI Hengjian, WANG Guanpeng, ZHENG Zhiwei

(School of Mathematical Sciences, Capital Normal University, Beijing 100048, China)

Abstract: Based on the data given in the 2021 HEP CUMCM problem B, exploratory data analysis was carried out on the conversion rate of ethanol and the selectivity of C4 olefins, and the effects of catalyst combination and temperature on ethanol were analyzed. The effects of conversion rate and C4 olefin selectivity were studied, and the multiple linear regression model and Logit transformation regression model were used for statistical study and exploration of the experimental data, and a feasible solution to the problem of "ethanol coupling to prepare C4 olefins" was given.

Key words: ethanol conversion rate; C4 olefin conversion rate; multiple linear regression model; Logit transformation model; variable screening

作者简介

崔恒建(1963—),男,教授,博士生导师,国务院学位委员会统计学科(2011—2014)评议组专家,中国现场统计学会副理事长,任《数学学报》和《应用数学学报》中、英文版以及《数理统计与管理》编委,研究方向为数理统计和稳健统计理论和方法、数学建模、金融统计、遥感统计与质量管理,发表论文 180 余篇,多篇刊发在统计和计量经济学领域国际顶级学术期刊上,主持国家自然科学基金重点项目并完成多项面上项目.

王冠鹏(1990—),男,首都师范大学三年级博士研究生,主要研究方向为数理统计.

郑志伟(1997—),男,首都师范大学二年级硕士研究生,主要研究方向为应用统计.