

教学与竞赛

“NIPT 的时点选择与胎儿的异常判定”赛题评述

赖 欣¹, 王嘉寅¹, 辛世纪¹, 崔恒建²

(1. 西安交通大学 计算机科学与技术学院, 陕西 西安 710049; 2. 首都师范大学 数学科学学院, 北京 100048)

摘 要: 本文对 2025 年“高教社杯”全国大学生数学建模竞赛 C 题“NIPT 的时点选择与胎儿的异常判定”作简要评述, 介绍赛题的概况和求解方法, 给出问题的解决算法和求解结果, 并列举参赛论文存在的主要问题。

关键词: 统计回归; 贪心切分; 分位数回归; 有监督学习

中图分类号: O29

文献标志码: A

文章编号: 2095-3070(2026)02-0020-18

DOI: 10.19943/j.2095-3070.jmmia.2026.02.03

1 问题概况与求解方法

2025 年“高教社杯”全国大学生数学建模竞赛 C 题“NIPT 的时点选择与胎儿的异常判定”^[1]是一道紧密结合医学临床实践、聚焦产前检测技术优化的典型数据建模问题。题目围绕无创产前检测(NIPT)的核心痛点展开——既要保证检测准确性以精准判定胎儿染色体异常, 又要通过合理选择检测时点降低孕妇潜在风险, 同时需兼顾个体差异对检测结果的影响, 具有极强的现实意义与应用价值。

赛题以 NIPT 技术原理为基础, 明确胎儿染色体浓度(尤其是男胎 Y 染色体浓度)是检测准确性的关键指标, 且该指标与孕妇孕周、BMI(身体质量指数)等个体特征强相关, 同时给出“早期发现风险低、晚期发现风险高”的临床规则, 为建模提供了清晰的约束条件与目标导向。附件提供的某地区高 BMI 孕妇的 NIPT 数据, 包含孕妇年龄、身高、体重、孕周、染色体 Z 值、浓度、测序读段数等多维度信息, 既贴近临床实际(如存在测序失败、多次检测情况), 也为问题求解提供了充足的数据支撑。

问题 1 聚焦“关系挖掘”, 要求分析胎儿 Y 染色体浓度与孕周、BMI 的相关特性并构建关系模型, 是后续优化问题的基础, 需参赛者熟练运用相关性分析、回归建模等方法, 并通过显著性检验验证模型可靠性。本文采用线性混合效应模型^[2]、二次多项式^[3]、样条函数等方法解决该问题。

问题 2 进入“分组与优化”阶段, 以男胎孕妇 BMI 为核心分组依据, 目标是确定每组最佳 NIPT 时点以最小化潜在风险。需在“浓度达标($\geq 4\%$)”与“时点尽早”之间找到平衡, 同时分析检测误差的影响, 考察多目标优化与不确定性分析能力。贪心切分算法^[4-5]的核心优势是通过“迭代切分、局部最优, 找到全局较优”的逻辑, 逐步将样本划分为异质性最小的子组。这与“以 BMI 为核心分组, 使每组内孕妇的 NIPT 时点决策目标(浓度达标、时点尽早)”的需求完全契合。

问题 3 进一步升级复杂度, 要求综合身高、体重、年龄等多因素, 结合达标比例与检测误差, 优化 BMI 分组与检测时点, 更贴近临床中“多因素共同影响检测结果”的实际场景, 需参赛者建立更全面的多变量决策模型。仍然使用贪心切分算法基于组间异质性对 BMI 分组。在组内最优 NIPT 时点的求

收稿日期: 2026-01-20

通信作者: 崔恒建, E-mail: hjcui@bnu.edu.cn

引用格式: 赖欣, 王嘉寅, 辛世纪, 等. “NIPT 的时点选择与胎儿的异常判定”赛题评述[J]. 数学建模及其应用, 2026, 15(2): 20-37.

LAI X, WANG J Y, XIN S J, et al. Review of the " timing selection for NIPT and fetal abnormality determination"(in Chinese)[J]. Mathematical Modeling and Its Applications, 2026, 15(2): 20-37.

解中,利用 Cox 比例风险模型^[6-7]自然地纳入多变量,使用分段线性风险函数进行风险校正,自定义联合损失函数来估计最优 NIPT 时点. Cox 比例风险模型作为生存分析的核心工具,在该场景中具备几个关键适配性:

- 多变量整合能力. 可同时纳入身高、体重、年龄等连续/分类变量,量化各因素对“检测不达标/误差过高风险”的独立或联合影响,满足“多因素共同决策”的需求;
- 时间维度天然适配. 孕周作为连续时间变量,能直接嵌入模型的时间轴,清晰刻画“随孕周推进,检测风险的动态变化规律”;
- 风险量化与可解释性. 通过输出风险比(hazard ratio, HR),可直观解释“某因素每变化一单位,检测风险的波动幅度”,为后续结合“达标比例、检测误差”进行时点优化提供量化依据;
- 删失数据的稳健性. 若存在“未到最优时点即终止观察”的删失样本,模型可有效处理,保障分析结果的可靠性.

综上, Cox 比例风险模型的“多变量兼容、时间维度嵌入、风险量化解释”的特性,与问题 3“综合多因素优化检测时点”的需求高度契合,因此是合适的技术选择. 文献[8]也通过多因素 Cox 模型整合孕周等变量,本文的风险函数构建与该文有相通之处.

问题 4 则本题转向女胎异常判定,跳出男胎 Y 染色体浓度的单一指标,围绕 21 号、18 号、13 号染色体非整倍体结果,整合 X 染色体 Z 值、GC 含量、读段数比例等多维度数据构建判定方法,考察参赛者对不同检测目标的建模适配能力. 具体实施时,本文先通过多维度样本质控筛选^[9](基于总读段数、比对率、重复率等指标),剔除低质量干扰样本;再将通过质控的样本按测序质量、数据可靠性分为优、中、差三档(如好样本、典型样本、临界样本),分别使用无监督学习和有监督学习针对每一档样本训练模型,并结合临床对假阳性样本严格约束,按不同置信水平(0.99 和 0.995)确定双阈值体系,最终形成阳性区、临界区、阴性区的判定逻辑:样本检测值 ≥ 0.995 置信水平对应的阈值,直接判定为异常(阳性),建议临床进一步确证;样本检测值介于 0.99 与 0.995 置信水平的阈值之间,判定为灰区(临界区),建议复检或结合其他临床指标综合判断;样本检测值 < 0.99 信水平对应的阈值,判定为正常(阴性),无需额外干预. 此方案通过“质量分层、分档建模、三区判定”,既适配不同检测目标的信号特征,又满足临床对精准性、安全性、可操作性的三重需求.

2 模型建立与问题求解结果

2.1 问题 1

采用线性混合效应模型 LMM(linear mixed model)^[2](含随机效应与二次项)分析 BMI 分组、孕周(gestational age, GA)及其非线性效应对胎儿 Y 染色体浓度(Y)的影响. 并且模型中引入了随机截距和孕周随机斜率^[10],用于捕捉个体间的随机差异. 模型为:

$$Y_{ij} = \beta_0 + \mu_{0i} + (\beta_1 + \mu_{1i})GA_{cij} + \sum_{k=1}^3 \gamma_k BMI_{group_{ik}} + \epsilon_{ij}, \quad (1)$$

其中: Y_{ij} 为第 i 个孕妇第 j 次观测的 Y 染色体浓度; γ_k 为 BMI 分组的哑变量(这里分组为 3 组,分别是 (28, 30.5]、(30.5, 36] 和 (36, 40]),用于刻画不同 BMI 区间的效应差异; GA_{cij} 为中心化孕周,捕捉孕周的线性效应; μ_{0i} 为随机截距; μ_{1i} 为 GA_{cij} 的随机斜率,是第 i 个孕妇的个体差异项,服从多元正态分布,用于刻画不同孕妇间 Y 浓度基线和孕周增长速率的随机变异; ϵ_{ij} 为残差项,代表模型未解释的随机误差,模型中各项系数见表 1.

表 1 固定效应

固定效应项	估值 (Estimate)	标准差 (Std. Error)	检验 t 值
β_0	0.076 295	0.001 591	47.941***
β_1	0.003 454	0.000 217	15.910***
γ_1	0.006 490	0.002 555	2.272*
γ_2	0.001 861	0.004 211	0.729
γ_3	-0.008 351	0.000 217	-1.983*

注: *** 表示 $p < 0.001$ (极显著); ** 表示 $p < 0.01$ (非常显著); * 表示 $p < 0.05$ (显著);无星号表示 $p \geq 0.05$ (不显著),表 3 含义相同.

计算效应方差与总方差之比 R^2 ^[11]，结果见表 2。用于量化不同来源的变异对响应变量总变异的贡献程度，衡量模型的解释力。

极显著变量：截距项 β_0 、中心化孕周 GA_c 的系数 β_1 ；

显著变量：BMI 分组 $G_1(\gamma_1)$ 和 $G_3(\gamma_3)$ ；

不显著变量：BMI 分组 $G_2(\gamma_2)$ 。

从图 1 可以看出， $\gamma_1, \gamma_2, \gamma_3$ 逐渐下降，说明 Y 染色体浓度水平随着 BMI 增加整体下降。

随机效应主导变异解释：随机效应总方差(0.000 835)远大于残差方差(0.000 177)，说明个体间差异(如不同孕妇的 Y 染色体浓度基线差异)是数据变异的主要来源，也验证了混合效应模型引入随机效应的必要性。

表 2 方差分析

指标名称	数值
随机效应总方差	0.000 835
残差方差	0.000 177
总方差	0.001 043
条件 R^2 (固定+随机效应解释力)	0.830 300
边际 R^2 (仅固定效应解释力)	0.030 200




图 1 $G_1 \sim G_3$ Y 浓度与孕周关系

模型整体拟合效果优异：条件 R^2 达 0.8303，意味着固定效应(BMI 分组、孕周)与随机效应共同解释了 83.03%的 Y 染色体浓度变异，模型对数据的整体拟合度极高。

固定效应解释力有限：边际 R^2 仅为 0.0302，表明仅靠 BMI 分组和孕周这两个固定效应，仅能解释 3.02%的变异，进一步凸显了个体间随机差异对 Y 染色体浓度的关键影响，后续分析可考虑补充更多个体特征变量以提升固定效应的解释力。

采用二次多项式回归(ordinary least squares, OLS)^[3]评估 BMI 与胎儿 Y 染色体浓度(Y)的关系，模型为：

$$Y=\beta_0+\beta_1 BMI+\beta_2 BMI^2+\epsilon. \tag{2}$$

有关结果见表 3、表 4 和表 5，Y 染色体浓度与 BMI 的关系见图 2。

表 3 系数估计

系数项	估计值	标准差	t 值	$\text{Pr}(> t)$	显著性
β_0	-1.548e-02	6.546e-02	-0.236	0.8131	不显著
β_1	7.179e-03	3.895e-03	1.843	0.0656	边缘显著
β_2	-1.323e-04	5.779e-05	-2.290	0.0222*	显著

表 4 系数置信区间

系数项	2.5%	97.5%
β_0	-1.44e-01	1.13e-01
β_1	-4.64e-04	1.48e-02
β_2	-2.46e-04	-1.89e-05

表 5 模型拟合与显著性评估

指标	数值
Residual standard error	0.033 08
Multiple R-squared	0.027 62
Adjusted R-squared	0.025 81
F(2, 1079)	15.32
p-value	2.744e-07

采用二次多项式回归(OLS)评估孕周(GA)与胎儿 Y 染色体浓度(Y)的关系,模型为:

$$Y=\beta_0+\beta_1GA+\beta_2GA^2+\epsilon.$$
 (3)

有关结果见表 6、表 7 和表 8, Y 染色体浓度与孕周的关系见图 3.

采用自然样条回归评估 BMI 与胎儿 Y 染色体浓度(Y)的关系,模型通过自然样条函数 ns(BMI, df=3)拟合 BMI 对 Y 的非线性影响.




图 2 Y 浓度与 BMI 的关系

表 6 系数估计

系数项	估计值	标准差	t 值	Pr (> t)	显著性
β_0	9.883e-02	2.10e-02	4.707	2.84e-06	显著
β_1	-3.543e-03	2.42e-03	-1.464	0.1434	不显著
β_2	1.267e-04	6.655e-05	1.904	0.0572	边缘显著

表 7 置信区间

系数项	置信区间	
	2.5%	97.5%
β_0	5.763e-02	1.4003e-01
β_1	-8.291e-03	1.204e-03
β_2	-3.869e-06	2.573e-04

表 8 模型拟合与显著性检验

指标	数值
Residual standard error	0.033 23
Multiple R-squared	0.019 28
Adjusted R-squared	0.017 46
F(2, 1078)	10.6
p-value	2.769e-05




图 3 Y 浓度与孕周关系

有关结果见表 9、表 10 和表 11, Y 染色体浓度与 BMI 的关系见图 4.

表 9 系数估计

系数项	估计值	标准差	t 值	Pr (> t)	显著性
Intercept	0.0400	0.0147	2.714	0.006 74	显著
ns(BMI, df=3)1	0.0011	0.0083	0.127	0.898 82	不显著
ns(BMI, df=3)2	0.0646	0.0303	2.131	0.033 33	显著
ns(BMI, df=3)3	-0.0123	0.0139	-0.882	0.377 76	不显著

表 10 置信区间

系数项	2.5%置信区间	97.5%置信区间
Intercept	0.011 10	0.068 97
ns(BMI, df=3)1	-0.015 30	0.017 44
ns(BMI, df=3)2	0.005 11	0.124 02
ns(BMI, df=3)3	-0.039 62	0.015 04

表 11 模型拟合与显著性分析

指标	数值
Residual standard error	0.032 93
Multiple R-squared	0.037 27
Adjusted R-squared	0.034 59
F(3, 1078)	13.91
p-value	6.648e-09




图 4 Y 浓度与 BMI 关系

采用自然样条回归评估孕周 (GA) 与胎儿 Y 染色体浓度 (Y) 的关系，模型通过自然样条函数 $ns(GA, df=3)$ 拟合 GA 对 Y 的非线性影响。

有关结果见表 12、表 13 和表 14，Y 染色体浓度与孕周的关系见图 5。

表 12 系数估计

系数项	估计值	标准差	t 值	Pr ($> t $)	显著性
Intercept	0.0588	0.003 84	15.303	$<2e-16$	显著
$ns(GA, df=3) 1$	-0.0200	0.005 57	-3.614	$3.16e-4$	显著
$ns(GA, df=3) 2$	0.0652	0.010 05	6.481	$1.38e-10$	显著
$ns(GA, df=3) 3$	0.0573	0.008 19	7.003	$4.40e-12$	显著

表 13 置信区间

系数项	2.5%	97.5%
Intercept	0.051 26	0.066 333
$ns(GA, df=3)1$	-0.031 04	-0.009 195
$ns(GA, df=3)2$	0.045 43	0.084 887
$ns(GA, df=3)3$	0.041 26	0.073 387

表 14 模型拟合与显著性分析

指标	数值
Residual standard error	0.032 75
Multiple R-squared	0.048 41
Adjusted R-squared	0.045 76
$F(3, 1077)$	18.26
p-value	$1.46e-11$




图 5 Y 浓度与孕周关系

由图 5 可以看出，Y 随 GA 呈现“先降后升”的非线性趋势，与自然样条的拟合形态一致：样条项 1 显著负向，对应孕周早期 Y 浓度随 GA 增加而下降；样条项 2 和 3 显著正向，对应孕周中晚期 Y 浓度随 GA 增加而上升，这与“孕周增加时胎儿发育成熟，胎盘来源含 Y 信号的 cfDNA 释放增多”的生理机制吻合。

2.2 问题 2

在医学数据驱动的决策优化问题中，如何对异质群体进行科学分组以实现精准干预，是提升临床实践效能的关键环节。以 NIPT 中胎儿染色体浓度的时点优化问题为例，孕妇 BMI、孕周等因素的复交互作用使得群体呈现显著异质性，若采用“一刀切”的检测策略，将难以平衡检测准确性与孕妇潜在风险。为此，贪心切分算法凭借其“逐步优化、局部最优导向全局最优”的特性，自然地成为解决此类多因素分层问题的有效工具。

它从“单一组别”出发，通过对每个当前组在特征 (如 BMI) 范围内的候选切点逐一试探，选择使组间异质性最大化的切分点，迭代至满足终止条件为止。这种策略既能够充分挖掘数据中的分层规律，又能避免过度分组导致的模型过拟合与临床应用复杂度飙升，从而在分组科学性与临床实用性之

间找到精妙平衡. 图 6 给出了贪心切分寻找最优 BMI 分组算法的过程描述, 算法有关说明如下.

将孕周(GA)先做全局中心化 $GAc = GA - \overline{GA}$, 保证各组截距具有可比性. 给定一组 BMI 切点 K , 将样本划分为若干组 $g = 1, 2, \dots, G$. 在每个组内拟合线性趋势:

$$Y_i = \alpha_g + \beta_g GAc_i + \epsilon_i, i \in g. \quad (4)$$

记各权重 $w_g = n_g$ (组内样本量), 以

$$\alpha = \sum_g w_g \alpha_g / \sum_g w_g, \beta = \sum_g w_g \beta_g / \sum_g w_g \quad (5)$$

定义异质性指标:

$$D(K) = \sum_{g=1}^G w_g [(\alpha_g - \alpha)^2 + (\beta_g - \beta)^2]. \quad (6)$$

为了在追求组间异质性的同时, 避免过度分组(过多的分组可能导致模型过拟合且增加临床应用复杂度), 引入目标函数:

$$\text{Objective} = D(K) - \lambda \cdot (k - 1), \quad (7)$$

其中: k 为分组的数量(即切点数量加 1); λ 为惩罚系数, 用于控制分组数量对目标函数的影响.

λ 越大, 对分组数量的惩罚越强, 越倾向于得到较少的分组; λ 越小, 越注重组间异质性的提升, 可能会得到较多的分组. 这里取 $\lambda = 0.0055$.

用贪心切分, 从一组开始, 对每个当前组在其 BMI 范围内的候选切点网格(两端留白且两侧样本 $\geq$ 阈值)逐一尝试, 选择能使目标函数 Objective 增幅最大的切点加入.

停止条件: $\Delta \text{Objective} < 0$, 或者迭代到最大组数. 这样得到仅基于 BMI 的“最优分组”.

基于男胎检测数据(剔除 A160), 按 BMI 贪心切分最大 Objective, 得到 3 个切点 28.48、30.57、36.04 来划分 BMI, 这样将样本划分为 4 组, 分别是:

$\leq 28.48 (n=49)$ 、 $(28.48, 30.57] (n=292)$ 、 $(30.57, 36.04] (n=626)$ 以及 $> 36.04 (n=111)$.

算法执行的切分结果如表 15 所示, 目标函数与分组数量关系见图 7, 分组情况见图 8.

表 15 切分结果

step	groups	$D(K)$	objective
1	0	0	0
2	1	0.074 048 03	0.068 548 03
3	2	0.086 626 40	0.075 626 40
4	3	0.092 386 28	0.075 886 28

Algorithm 1: 贪心切分寻找最优 BMI 分组算法

Input: 男性胎儿孕妇数据 (包括 BMI、GA 等)

Output: 最优 BMI 分组、各组 BMI 区间及最佳 NIPT 时间点

计算 $GAc = GA - \overline{GA}$, 其中 $\overline{GA}$ 为 GA 的全局均值;

初始化分组为包含所有样本的一个组;

while 未满足停止条件 ($\Delta \text{Objective} < 0$ 或达到最大分组数) do

for 每个当前组 g do

在组 g 的 BMI 范围内生成候选切点网格 (两端留白且两侧样本量 $\geq$ 阈值);

for 网格中的每个候选切点 K do

用 K 将组 g 分为两个子组;

对每个子组拟合线性趋势 $y_i = \alpha_g + \beta_g GAc_i + \epsilon_i (i \in g)$;

计算组权重 $w_g = n_g$ (其中 n_g 为组内样本量);

计算 $\bar{\alpha} = \sum_g w_g \alpha_g / \sum_g w_g, \bar{\beta} = \sum_g w_g \beta_g / \sum_g w_g$;

计算异质性指数 $D(K) = \sum_g w_g [(\alpha_g - \bar{\alpha})^2 + (\beta_g - \bar{\beta})^2]$;

设 k 为当前分组数 (拆分后 k 增加 1);

计算目标函数 $\text{Objective} = D(K) - \lambda \cdot (k - 1)$;

记录使目标函数增幅最大的切点 K ;

end

end

若存在使目标函数增加的切点, 则执行拆分;

否则, 停止迭代;

end

根据最终切点确定各组 BMI 区间;

return 最优 BMI 分组、各组 BMI 区间

图 6 贪心切分算法




图 7 目标函数-分组数量

在 BMI 最优分组内, 用线性分位数回归^[12]描述 Y 随孕周的变化

$$Q_\tau(Y | GA) = \alpha_\tau + \beta_\tau GA, \tau \in \{0.30, 0.20\}, \quad (8)$$

求解

$$\alpha_\tau + \beta_\tau GA_{\tau,g}^* = 0.04, \quad (9)$$

得到该组在置信水平 $(1-\tau)$ 下的最早起测孕周 $GA_{\tau,g}^*$ (并限制在该组的观测孕周区间内). $\tau = 0.30$ 对应“约 70% 个体可达标”的时点, $\tau = 0.20$ 对应“约 80% 个体可达标”的更保守时点. 实现用到的包: readxl(读取 Excel)、dplyr(整理)、quantreg(分位数回归)和 ggplot2(可视化), 结果如表 16 所示.




图 8 分组情况

表 16 BMI 分组的最优检测时点

BMI 组	n	τ	α	β	$GA_{\min}$	$GA_{\max}$	GA^*
$[-\text{Inf}, 28.5]$	49	0.3	0.004 11	0.002 800	14.43	25.29	12.80
$[-\text{Inf}, 28.5]$	49	0.2	-0.011 60	0.003 250	11.43	25.29	15.87
$(28.5, 30.6]$	292	0.3	0.032 20	0.001 900	11.00	26.14	NA
$(28.5, 30.6]$	292	0.2	0.033 70	0.001 200	11.00	26.14	NA
$(30.6, 36]$	626	0.3	0.054 90	0.000 140	11.00	29.00	NA
$(30.6, 36]$	626	0.2	0.047 20	0.000 116	11.00	29.00	NA
$(36, \text{Inf}]$	111	0.3	0.016 90	0.000 130	11.29	26.43	17.80
$(36, \text{Inf}]$	111	0.2	0.022 80	0.000 543	11.29	26.43	NA

表 16 中, 第一列 BMI 组表示按切点 28.48, 30.57, 36.04 划分的区间; 第二列 n 表示该 BMI 组内样本量; 第三列 τ 表示分位数水平, $\tau=0.30$ 是主结果, 表示 70% 达标, $\tau=0.20$ 是保守结果, 表示 80% 达标; α 和 β 分别表示该组分位数回归 $Q_{\tau}(Y | GA) = \alpha + \beta GA$ 的截距与斜率; $GA_{\min}/GA_{\max}$ 分别表示该 BMI 组内孕周观测范围的下/上限(周); GA^* 表示在该组观测范围内解出的最早起测孕周. GA^* , 若为 NA, 含义有二, 一是若 $GA^* < GA_{\min}$, 表示从第 11 周就已达标(见(28.5, 30.6]、(30.6, 36]两组), 二是若 $GA^* > GA_{\max}$, 表示在本组观测窗口内尚未达到 4%(见 >36 组在 $\tau=0.20$ 的情形).

基于“男胎检测数据”, 按 BMI 贪心切分最大化 Objective 得到的 3 个切点(28.48, 30.57, 36.04), 形成 4 个 BMI 组, 随后在每个 BMI 组内, 用分位数回归 $Q_{\tau}(Y | GA) = \alpha + \beta GA$, 解方程 $Q_{\tau}=0.04$, 得到该组在置信水平 $(1-\tau)$ 下的最早起测孕周 GA_{τ}^* (限制在该组的观测孕周区间 $[GA_{\min}, GA_{\max}]$ 内). 结果如下:

- $\leq 28.48 (n=49)$, $\tau=0.30$ 时 $GA^* \approx 12.8$ 周, $\tau=0.20$ 时 $GA^* \approx 15.9$ 周;
- $(28.48, 30.57] (n=292)$, $\tau=0.30$ 与 $\tau=0.20$ 的交点均在本组观测下限之前 ($GA^* < GA_{\min} = 11.0$ 周), 意味着从第 11 周开始就可以进行检测;
- $(30.57, 36.04] (n=626)$, 同上, $\tau=0.30/0.20$ 在 11 周开始就可以进行检测;
- $> 36.04 (n=111)$, $\tau=0.30$ 时 $GA^* \approx 17.8$ 周, $\tau=0.20$ 在本组观测上限内尚未达到.

中间两组 BMI 的分组从第 11 周开始就可以进行检查是因为该 BMI 区间更接近普遍人群范围, 普遍来说, 11 周左右就可以开始检查; 而两端的分组呈现不同情形, 最高 BMI 组 (>36) 在 11 周的下分位预测仅 $\approx 3.1\%$, 需要到 17.8 周 ($\tau=0.30$) 才越过 4%, 这与高 BMI 可能带来的母体 cfDNA 稀释、使胎儿比例偏低的常见现象相一致; 而最低 BMI 组 (≤ 28.5) 在本数据的 11 周下分位仍略低于 4%, 具体结果见表 17.

表 17 BMI 分组考虑孕周风险的最优检测时点

BMI 组	τ	$\lambda=0.2$	$\lambda=0.3$	$\lambda=0.4$	$\lambda=0.5$	$\lambda=0.6$
$[-\text{Inf}, 28.5]$	0.3	12.13	12.03	11.93	11.93	11.53
$[-\text{Inf}, 28.5]$	0.2	15.43	15.03	14.63	13.93	13.03
$(28.5, 30.6]$	0.3	NA	NA	NA	NA	NA
$(28.5, 30.6]$	0.2	NA	NA	NA	NA	NA
$(30.6, 36]$	0.3	NA	NA	NA	NA	NA
$(30.6, 36]$	0.2	NA	NA	NA	NA	NA
$(36, \text{Inf}]$	0.3	14.79	12.69	11.99	11.99	11.79
$(36, \text{Inf}]$	0.2	14.59	11.99	11.99	NA	NA

为了融入孕周风险,定义分段线性基函数^[13](结点 12/27/28 周):

$$b_E(t) = \min\{t, 12\}, \quad b_M(t) = \max\{\min\{t, 27\} - 12, 0\}, \quad b_L(t) = \max\{t - 28, 0\}.$$

原始风险:

$$r_{\text{raw}}(t) = \beta_E b_E(t) + \beta_M b_M(t) + \beta_L b_L(t), \quad (10)$$

归一化(区间 $[t_0, t_1] = [10, 40]$), 得到最终的分段线性风险函数:

$$\text{Risk}(t) = \text{clip}\left(\frac{r_{\text{raw}}(t) - r_{\text{raw}}(t_0)}{r_{\text{raw}}(t_1) - r_{\text{raw}}(t_0)}, 0, 1\right). \quad (11)$$

斜率比设定 $\beta_E : \beta_M : \beta_L = 1 : 3 : 6$, 体现“晚期极高”的定性先验: 让晚期斜率 β_L 显著大于中期/早期(约为中期的 2 倍、早期的 6 倍), 结合各段长度(早期约 12 周、中期 15 周、晚期 12 周), 累计惩罚量近似 $\beta \times \text{段长}$ (早期 ≈ 12 、中期 ≈ 45 、晚期 ≈ 72), 从而晚期 $\gg$ 中期 $\gg$ 早期。

最终的联合损失函数:

$$L(\text{GA}_g) = (1 - \lambda) \left(\frac{\alpha_{g\tau} + \gamma_{g\tau} \text{GA}_g - 0.04}{0.04} \right)^2 + \lambda \text{Risk}(\text{GA}_g), \quad (12)$$

$$\hat{\text{GA}}_g = \underset{\text{GA}_g}{\text{argmin}} L(\text{GA}_g),$$

$$\text{s. t. } \text{GA}_g \in [\text{GA}_{gm}, \text{GA}_{gM}]. \quad (13)$$

$\text{GA}_{\text{risk}}^*$ 是在计算最早起测孕周时, 纳入了孕周风险函数(分段线性, 孕初、孕中、孕末斜率比为 $1 : 3 : 6$)后的结果. 这个风险函数考虑了不同孕周阶段(孕初、孕中、孕末)的风险差异, 通过赋予不同斜率来体现, 使得计算出的起测孕周更能反映实际的风险情况, 让起测时间的确定与孕周相关风险更契合. 这里选取了 $\lambda = 0.2, 0.3, 0.4, 0.5, 0.6$ 几个不同的取值, 展示风险权重对最优检测孕周的影响规律. 随着 λ 增大, 最优检测时点不断前移, 可以看到引入孕周风险函数有效矫正了分位数回归最优检测时点偏大的缺点.

检测误差分析见表 18—20.

表 18 误差分析 I

BMI 组	n	τ	$\text{GA}_{\min}$	$\text{GA}_{\max}$	GA^*	GA_{Lo}^*	GA_{Uo}^*
$[-\text{Inf}, 28.5]$	49	0.3	14.43	25.29	12.80	12.30	13.30
$[-\text{Inf}, 28.5]$	49	0.2	11.43	25.29	15.87	12.16	19.51
$(28.5, 30.6]$	292	0.3	11.00	26.14	NA	11.68	19.71
$(28.5, 30.6]$	292	0.2	11.00	26.14	NA	11.29	19.61
$(30.6, 36]$	626	0.3	11.00	29.00	NA	11.68	28.80
$(30.6, 36]$	626	0.2	11.00	29.00	NA	11.68	28.80
$(36, \text{Inf}]$	111	0.3	11.29	26.43	17.80	14.25	24.10
$(36, \text{Inf}]$	111	0.2	11.29	26.43	NA	14.92	24.92

表 19 误差分析 II

BMI 组	τ	$\hat{\beta}$	β_{L0}	β_{U0}	BMI 组	τ	$\hat{\beta}$	β_{L0}	β_{U0}
$[-\text{Inf}, 28.5]$	0.3	1.26e-03	0.004 340	0.004 34	$(30.6, 36]$	0.3	-6.11e-04	0.000 095	0.000 095
$[-\text{Inf}, 28.5]$	0.2	1.47e-03	0.004 286	0.004 286	$(30.6, 36]$	0.2	-6.57e-04	0.000 095	0.000 095
$(28.5, 30.6]$	0.3	-4.80e-04	0.001 959	0.001 959	$(36, \text{Inf}]$	0.3	-3.25e-05	0.001 660	0.001 660
$(28.5, 30.6]$	0.2	-6.57e-04	0.001 203	0.001 203	$(36, \text{Inf}]$	0.2	-7.94e-04	0.000 270	0.000 270

表 20 误差分析 III

BMI 组	τ	$\lambda=0.2$	$\lambda=0.3$	$\lambda=0.4$	$\lambda=0.5$	$\lambda=0.6$
$[-\text{Inf}, 28.5]$	0.3	12.13	12.03	11.93	11.93	11.53
$[-\text{Inf}, 28.5]$	0.2	15.43	15.03	14.63	13.93	13.03
$(28.5, 30.6]$	0.3	NA	NA	NA	NA	NA
$(28.5, 30.6]$	0.2	NA	NA	NA	NA	NA
$(30.6, 36]$	0.3	NA	NA	NA	NA	NA
$(30.6, 36]$	0.2	NA	NA	NA	NA	NA
$(36, \text{Inf}]$	0.3	14.79	12.69	11.99	11.99	11.79
$(36, \text{Inf}]$	0.2	14.59	11.99	11.99	NA	NA

在已确定的 BMI 最优分组 (≤ 28.5 , $28.5 \sim 30.6$, $30.6 \sim 36$, > 36) 基础上, 不改变分组与模型, 只给最早达标孕周配上误差与不确定性. 每一 BMI 组内, 首先用线性分位数回归建立关系模型

$$Q_{\tau}\{Y \mid \text{GA}\} = a_{g,\tau} + b_{g,\tau} \cdot \text{GA},$$

其中: Y 为 Y 染色体浓度; GA 为孕周; $\tau \in \{0.30, 0.20\}$ 分别对应约 70%/80% 达标概率. 阈值设为 $Y^* = 0.04$, 最早达标孕周定义为

$$\text{GA}_{g,\tau}^* = (Y^* - a_{g,\tau}) / b_{g,\tau},$$

若交点落在本组观测孕周区间外则记为 NA. 考虑到同一孕妇可能多次检测、观测并非独立, 按“孕妇 ID”做簇级 (cluster) bootstrap: 每次整簇重采样 (抽孕妇并带上她的全部记录), 重复拟合并重算 $\text{GA}_{g,\tau}^*$, 以获得 95% 置信区间. 同时, 为把一次检测的随机波动 (建库) 测序/定量误差及模型未解释的起伏) 纳入决策, 以分位数回归残差的 MAD (中位绝对偏差, 稳健估计的 σ) 刻画“噪声幅度”, 并将分位数曲线下移 $z_{0.95} \times \text{MAD}$ ($z_{0.95} = 1.645$), 得到保守曲线; 其与 4% 的交点记为保守 GA^* . 直观理解: 保守 GA^* 表示“在该孕周, 考虑 95% 的测量抖动, 一次检测也几乎能过 4%”.

在 ≤ 28.5 组 ($n=49$), 基准结论为: $\tau=0.30$ 时 $\text{GA}^* \approx 12.8$ 周 (95%CI 12.3~23.0), $\tau=0.20$ 时 15.9 周 (95%CI 12.3~19.7), 且斜率的 95%CI > 0 , 提示“孕周 $\uparrow \rightarrow Y \uparrow$ ”在此组显著成立; 但加入安全边际后, 保守 GA^* 在本组观测范围内不可保证一次达标 (为 NA), 说明若要求“95% 一次稳过”, 需要更晚或接受复检.

$28.5 \sim 30.6$ 组 ($n=292$) 与 $30.6 \sim 36$ 组 ($n=626$) 中, $\tau=0.30$ 的交点不可识别 (NA), $\tau=0.20$ 的 95%CI 仍很宽 (分别为 11.16~25.61 与 11.68~28.80), 斜率 CI 跨 0, 显示“阈值交点对噪声高度敏感”; 加入安全边际后, 两组的保守 GA^* 同样不可保证一次达标 (NA).

> 36 组 ($n=111$) 中, $\tau=0.30$ 的点估约 17.8 周 (95%CI 14.25~24.12, 斜率 CI > 0), 而 $\tau=0.20$ 的交点为 NA; 加入安全边际后, 保守 GA^* 亦超出本组观测上限 (NA), 提示高 BMI 人群受检测误差影响最大, 若要“95% 一次稳过”, 起测孕周需要进一步推迟.

综上, 检测误差会把“最早达标时间”整体向后推, 且 BMI 越高推得越多. 因此建议把“单个最早时点”转化为“起测+复检”的流程: 1) BMI ≤ 36 时, 在 11~12 周安排首次 NIPT; 若 $< 4\%$, 2~4 周后复检 (必要时再次复检). 基准 GA^* ($\tau=0.30/0.20$) 可作为“多数能过”的参考, 但若接近“一

次稳过”，应依赖复检来对冲测量抖动。2) BMI > 36 时，若希望一次通过概率更高，建议 18 周左右再检，或 11~12 周先检并预设 2~4 周后复检。

2.3 问题 3

在探究男胎孕妇最佳 NIPT 检测时点的问题中，聚焦于“胎儿 Y 染色体浓度首次达到或超过 4% 的孕周”这一核心事件，它涉及带删失的时间-事件分析、多因素影响整合及检测效益与孕期安全的权衡。首先，由于真实达标时间存在区间删失（夹在相邻检测孕周间）、左删失（首条即达标）或右删失（末次仍未达标）的情况，Cox 比例风险模型成为天然适配的分析工具，能自然且无偏地估计“任意孕周 t 已达标”的概率，并求解覆盖某一比例 q 的最早起测孕周 t_q 。

为了精准刻画孕周对达标风险的动态影响，引入分段线性基函数，以 12 周、27 周、28 周为结点构建分段线性风险函数 $r(t)$ ，捕捉早期（≤12 周）、中期（13~27 周）、晚期（≥28 周）Y 染色体浓度变化速率的异质性。通过 $\beta_E : \beta_M : \beta_L = 1 : 3 : 6$ 的先验设定，体现“晚期风险增长远高于中期、早期”的临床认知，再经归一化操作，将风险映射到 $[0, 1]$ 区间以规范取值。

同时，由于 BMI 已经包含了身高体重的影响，这里只考虑 BMI 组号和年龄因素对达标时间的影响，继续沿用问题 2 中的贪心切分算法对 BMI 进行合理分组，以挖掘不同 BMI 人群的达标时间差异。通过整合 Cox 比例风险模型、分段线性风险函数与贪心切分，旨在综合考量检测成功率、孕期安全性、多因素影响及检测误差，为不同 BMI 分组的男胎孕妇提供最佳 NIPT 检测时点，最小化孕妇潜在风险，进而为临床 NIPT 检测时机的选择提供科学且个性化的决策支持。

首先，仍然使用问题 2 中的贪心切分算法，确定 BMI 分组区间。为消除不同协变量量纲差异、增强模型稳定性，对身高 (H)、体重 (W)、年龄 (A) 进行标准化 (Z-score 归一化)，公式为：

$$X_c = \frac{X - \bar{X}}{\text{sd}(X)},$$

其中： $\bar{X}$ 为协变量 X 的均值； $\text{sd}(X)$ 为协变量 X 的标准差； X_c 为标准化后的协变量。同时，对孕周 (GA) 进行均值中心化（保证组间截距可比性）：

$$GA_c = GA - \overline{GA},$$

其中， $\overline{GA}$ 为所有样本孕周的均值。

给定一组 BMI 切点 K ，将样本划分为 $g = 1, 2, \dots, G$ 组。在每组内，假设 Y 染色体浓度的均值与标准化协变量 (Age_c) 存在线性关系：

$$Y_i = \alpha_g + \beta_{g, Age} \cdot Age_{c,i} + \epsilon_i, \quad i \in g, \quad (14)$$

其中： α_g 是第 g 组的基础浓度截距； $\beta_{g, Age}$ 是第 g 组内年龄协变量对 Y 的影响系数； ϵ_i 是随机误差（含检测误差等）。

为衡量不同 BMI 组间的差异程度，定义异质性指标：

$$D(K) = \sum_{g=1}^G w_g [(\alpha_g - \bar{\alpha})^2 + (\beta_{g, Age} - \bar{\beta}_X)^2 + (Y_{\text{mean},g} - \bar{Y}_{\text{mean}})^2], \quad (15)$$

其中： $Y_{\text{mean},g}$ 是第 g 组的 Y 染色体浓度均值； $\bar{Y}_{\text{mean}}$ 是所有样本的 Y 染色体浓度均值，考虑该变量的原因是让每组拟合的 Cox 模型的生存曲线差异度更大。

计算所有组截距与系数的加权均值（权重为组内样本量 $w_g = n_g$ ）；异质性指标 D 为各组截距与系数偏离整体均值的加权平方和， D 越大，说明不同 BMI 组的基础浓度和协变量影响差异越显著，分组的区分度越高。通过贪心迭代寻找使目标函数 $\text{Objective} = D(K) - \lambda(k-1)$ 最大化的 BMI 切点集合 K （其中 k 为当前分组数， λ 为预设惩罚系数，用于平衡异质性提升与分组数量增加），步骤如下。

步骤 1 初始状态。所有样本为 1 组（此时 $k=1$ ），计算初始异质性 D_0 ，并代入目标函数得初始值 $\text{Objective}_0 = D_0 - \lambda(1-1) = D_0$ 。

步骤 2 迭代切分。对当前的 k 个组，分别在每个组的 BMI 范围内生成候选切点网格（需满足两端留白，且切分后网格两侧的样本量均不小于最小阈值）。

步骤 3 选择最优切点. 计算每个候选切点切分后新分组方案下的异质性 D_{new} (此时分组数变为 $k+1$), 并代入目标函数计算 $\text{Objective}_{\text{new}} = D_{\text{new}} - \lambda [(k+1) - 1]$; 选择使 $\text{Objective}_{\text{new}} - \text{Objective}_{\text{old}}$ (即目标函数增幅) 最大的切点, 将其加入切点集合 K , 同时更新分组数为 $k+1$ 、目标函数值为 $\text{Objective}_{\text{new}}$, 这里取 $\lambda = 0.004$.

步骤 4 终止条件. 迭代至以下任一条件满足时停止:

i) 当前分组数达到预设最大组数;

ii) 目标函数的增幅 $(\text{Objective}_{\text{new}} - \text{Objective}_{\text{old}}) < 0$, 即继续切分对目标函数没有提升.

根据目标函数随分组数量变化的结果(图 9), 最终确定 BMI 切分方案, 切点分别为 29.4、30.4 和 33.9. 相应的 BMI 各分组见表 21, 切分结果见表 22.




图 9 目标函数与分组数量关系

表 21 BMI 切点及分组参数

分组	α	β_{age}
$[-\text{Inf}, 29.4]$	0.090	-0.007
$(29.4, 30.4]$	0.088	-0.001
$(30.4, 33.9]$	0.078	0.000
$(33.9, \text{Inf}]$	0.064	0.001

表 22 切分结果

step	groups	D	objective
1	0	0	0
2	1	0.015 595 80	0.011 595 80
3	2	0.021 597 00	0.013 597 00
4	3	0.028 070 99	0.016 071 00

对 BMI 分组后, 求每组最佳检测时间. 估计“胎儿 Y 染色体浓度首次达到或超过 4% 的孕周”这一事件时间 T 的分布, 并据此在不同 BMI 人群上给出“在孕周 t 前已达标”的概率 $F(t) = \Pr(T \leq t)$ 及其分位点 t_q (例如 $q = 70\%$, 80%). 由于同一孕妇存在多次检测, 真实的首次达标时间只知落在相邻两次采样孕周之间, 属于区间删失(interval censoring)问题, 个别情形还会出现左删失(首条即达标)或右删失(至末次仍未达标). 生存分析正是为“处理含删失的生存时间数据”而设计的: 其目标函数直接基于生存函数 $S(t) = \Pr(T > t)$ 或分布函数 $F(t) = 1 - S(t)$ 来构建似然函数, 从而可以自然、无偏地计算“在任意孕周 t 已达标”的概率, 并求解覆盖率为 q 的最早起测孕周 $t_q = \inf t: F(t) \geq q$.

在相邻两次采样孕周之间, 属于区间删失(interval censoring)问题, 个别情形还会出现左删失(首条即达标)或右删失(至末次仍未达标). 生存分析正是为“处理含删失的生存时间数据”而设计的: 其目标函数直接基于生存函数 $S(t) = \Pr(T > t)$ 或分布函数 $F(t) = 1 - S(t)$ 来构建似然函数, 从而可以自然、无偏地计算“在任意孕周 t 已达标”的概率, 并求解覆盖率为 q 的最早起测孕周 $t_q = \inf t: F(t) \geq q$.

以孕妇个体为分析单位, 将同一孕妇的多次检测记录按孕周排序, 构造其首次达标时间的区间观测 $(L_i, R_i]$: 若某孕妇在第 j 次检测首次满足 $Y \geq 0.04$, 则 L_i 为前一次未达标检测孕周, R_i 为本次达标孕周; 若首条记录即 $Y \geq 0.04$ 则为左删失 $(\epsilon, R_i]$; 若始终 $Y < 0.04$ 则为右删失 $(L_i, +\infty)$. 为增强“首次达标”判定稳健性, 若同一孕周有多次检测, 先对该孕周取 Y 的最大值再判定. BMI 以孕妇层面的均值代表, 年龄以样本均值中心化 (Age_c) 后纳入模型以控制年龄差. 所有区间以 survival: Surv(L, R , type = “interval2”)形式输入. 为避免区间完全重合导致数值退化, 对 $(L, R]$ 引入随机噪声并确保 $L > 0, R > L$. 尝试区间删失的 Cox 比例风险模型:

$$\lambda(t | \mathbf{X}) = \lambda_0(t) \exp(\mathbf{X}^T \boldsymbol{\beta}), S(t | \mathbf{X}) = [S_0(t)] \exp(\mathbf{X}^T \boldsymbol{\beta}). \quad (16)$$

在男胎样本中, 按 BMI 分组, 给出各组的最佳 NIPT 检测时段, “最佳”定义为在“检测成功率”与“孕期安全性”之间取得最优权衡的时间点.

定义事件发生: $Y \geq 0.04$, 构建随孕周递增的孕期风险函数 $\text{Risk}(t) \in [0, 1]$ (据题面“早期低/中期高/晚期极高”以孕周分段线性定义综合评分):

$$J(t) = -\log[(1 - S(t|x))] + \lambda(1 - \text{Risk}(t)), \quad (17)$$

其中, $\text{Risk}(t)$ 使用式(11)定义的分段线性风险函数, λ 取 0.4.

在可行孕周域 T (如 12~30 周) 内取最大点 $t^* = \arg\max_{t \in T} J(t)$, 即各 BMI 组的最佳检测时段. 在每个 BMI 组(以及身高、体重、年龄协变量)上拟合:

$$h(t|\mathbf{x}) = h_0(t) \exp(\boldsymbol{\beta}^T \mathbf{x}), \quad (18)$$

$$S(t|\mathbf{x}) = \exp(-\int (u|\mathbf{x}) du) = S_0(t) \exp(\boldsymbol{\beta}^T \mathbf{X}), \quad (19)$$

其中, $S(t|\mathbf{x})$ 为生存函数, 表示 t 时刻 $Y < 0.04$ 的概率.

$$\text{Surv}(L, R) \sim \text{BMI}_{\text{group}} + \text{Age}_{\text{std}} + \text{Height}_{\text{std}} + \text{Weight}_{\text{std}}. \quad (20)$$

拟合的系数估计及拟合指标分别见表 23 和 24.

表 23 系数估计

协变量	系数值	协变量	系数值
$\text{BMI}_{\text{group}} \in [29.4, 30.4]$	-0.238	Age_{std}	-0.051
$\text{BMI}_{\text{group}} \in [30.4, 33.9]$	0.294	$\text{Height}_{\text{std}}$	0.128
$\text{BMI}_{\text{group}} \in [33.9, \text{Inf}]$	0.083	$\text{Weight}_{\text{std}}$	-0.349

在给定的 BMI 分组下, 4 组的最佳检测时点 t^* 分别为: $\text{BMI} \in [-\text{Inf}, 29.6]$ 是 13.1 周(40 人), $(29.6, 30.6]$ 是 17.0 周(47 人), $(30.6, 31.5]$ 是 13.1 周(40 人), $(31.5, \text{Inf}]$ 是 13.1 周(139 人).

表 24 拟合指标

模型拟合指标	数值
BIC	353.63
对数似然值	-160.06

检测误差分析: 误差发生在观测量 Y (染色体浓度 $\{Y \geq 0.04\}$), 现实里 Y 受检测噪声影响, 同一孕周重复取样的 Y 会有抖动. 建立噪声:

$$Y^{(\text{obs})} = Y^{(\text{true})} + \varepsilon, \varepsilon \sim N(0, \sigma^2), \quad (21)$$

其中, $\hat{\sigma}$ 用分位回归残差的 MAD 估计^[14] (稳健、抗极值).

在已经确定的最优 BMI 分组不变的前提下, 只对观测量 Y 加噪声、重建 $(L, R]$ 、重拟合 Cox, 并重复计算各组的 t^* .

噪声方差估计: $\hat{\sigma} \approx 0.0232(\text{MAD})$.

基准各组 t^* 分别为 13.1/17.0/13.1/13.1 周. 在仅对观测量 Y 加入 $N(0, \sigma^2)$ 扰动 ($\sigma \approx 0.0232$) 并重复 200 次后, 4 组 t^* 的均值约为 15.3/15.3/14.8/14.2 周, 对应区间分别为 $[13.3, 20.0]/[13.4, 19.5]/[13.3, 17.4]/[13.0, 17.0]$ 见表 25. 与基准相比, 综合最优时点变化为 $+2.2/-1.7/+1.7/+1.1$ 周.

表 25 噪声分析

BMI 组	n	t^*	t_{lo}^*	t_{hi}^*	t_{mean}^*	t_{sd}^*
$[-\text{Inf}, 29.6]$	40	13.1	13.3	20.0	15.3	1.870
$(29.6, 30.6]$	47	17.0	13.4	19.5	15.3	1.710
$(30.6, 31.5]$	40	13.1	13.3	17.4	14.8	1.380
$(31.5, \text{Inf}]$	139	13.1	13.0	17.0	14.2	0.914

在噪声扰动下, 大多数组的最佳检测时点出现轻微延后, 结合“首次越界(first-hit)”机制及晚期真实值的主导作用来看: “首次越界”规则下, 若早期 Y 真实值未达标但正噪声致观测值误判达标, 事件时间会锁定在更早孕周, 后续负噪声也无法改变; 可实际模拟中最佳时点轻微延后, 核心是晚期真实值对噪声的抵消作用. 随着孕周推进, Y 真实值逐渐升高, 更易稳定超 0.04 阈值. 早期 Y 真实值低, 与阈值差距大, “早期误命中”有一定概率, 且此时 $1-r(t)$ 大, $J(t)$ 峰值易偏向早周; 到中晚期, Y 真实值达标概率显著提升, 噪声干扰相对减弱, “首次越界”更可能基于真实达标进程. 同时, 评分函数 $J(t) = (1-r(t))(1-S(t))$ 里, 晚期 $r(t)$ 高 ($1-r(t)$ 降低), 但 $1-S(t)$ 增长幅度更显著, 对 $J(t)$ 的正向贡献超过 $1-r(t)$ 的负向影响. 早期“首次越界”误判导致的生存曲线左移效应, 在晚期被真实值主导的达标概率提升抵消, 最终使 $J(t)$ 峰值在多次模拟中向稍晚孕周偏移, 体现出“首次越界”偏差在早期影响有限, 也反映出晚期真实值对噪声更强的抵抗能力, 让最佳时点更贴近真实达标进程.

2.4 问题 4

在确定最佳 NIPT 检测时点后, 胎儿染色体异常的精准判定成为核心目标, 这一过程需兼顾数据可靠性、特征挖掘效率与诊断模型的泛化能力. 首先, NIPT 检测依赖孕妇外周血中游离胎儿 DNA 的扩增与分析, 样本采集、核酸提取及测序过程中可能引入污染、降解等干扰因素, 直接影响后续判定结果的准确性. 因此, 质控是异常判定的前提基础, 需通过样本水平与基因水平的双重校验, 剔除异常样本与低质量数据, 确保输入数据的可靠性, 为后续分析提供纯净的数据基础.

为高效挖掘数据潜在规律, 无监督算法的引入至关重要. 此类算法无需依赖标注信息, 可通过主成分分析降维揭示特征间的隐性关联, 或借助层次聚类、 K -均值聚类等方法探索样本间的相似性与变异来源, 识别数据中的异常值或潜在分组模式. 由于样本无真阳性标注, 本文创新性地按照假阳率对样本进行分组, 以此在无监督框架下划分数据簇, 为后续异常判定划定初步范围, 提供关键线索, 同时辅助质控环节验证样本的一致性.

基于质控后的数据与无监督算法挖掘的特征, 有监督算法可进一步实现异常的精准分类与判定. 通过利用已知异常标签的样本训练模型(如逻辑回归、随机森林、支持向量机等), 学习正常与异常样本的关键差异特征, 最终输出分类阈值 Z ——该阈值是区分“异常”与“正常”的量化边界, 能够精准量化染色体异常的风险概率, 显著提升判定的特异性与灵敏度.

质控、无监督算法与有监督算法的有机结合, 形成了“数据净化(质控)—特征挖掘(无监督, 输入样本特征)—精准判定(有监督, 输出分类阈值 Z)”的完整逻辑链, 既保障了分析的可靠性, 又兼顾了效率与准确性, 为胎儿染色体异常的临床诊断提供了科学、系统的技术支撑.

严格标签(AE+AB)下, chr13/18/21 三条染色体均未检出阳性个案, 因此无法训练监督式分类器(逻辑回归/支持向量机等).

本文在女胎检测数据上构建随测序质量与个体特征自适应的判定边界. 为避免极端质量样本对边界学习的干扰, 首先对质量变量作非参数质控. 记 $X \in \{L, M, N, O, AA\}$, 其经验分布函数为 $\hat{F}_X(x)$, 则第 p 分位数定义为

$$\hat{Q}_p(X) = \inf x: \hat{F}_X(x) \geq p. \quad (22)$$

采用“中心 90% 截断”的对称门槛: 对“越大越好”的指标(如总读段数 L 、比对比例 M 、唯一比对比例 O)保留 $[\hat{Q}_{0.05}(X), +\infty)$; 对“越小越好”的指标(如重复率 N 、过滤比例 AA)保留 $(-\infty, \hat{Q}_{0.95}(X)]$. 因此, 通过质控的样本满足

$$L \geq \hat{Q}_{0.05}(L), M \geq \hat{Q}_{0.05}(M), O \geq \hat{Q}_{0.05}(O), N \leq \hat{Q}_{0.95}(N), AA \leq \hat{Q}_{0.95}(AA).$$

选择 5%/95% 的逻辑是: 一方面用经验分位数在分布形状未知时对异常尾部(测序失败、污染、极端体质等)进行稳健截断; 另一方面保持足够样本量(约 90%)用于阈值估计, 降低小样本噪声. 对称的 5/95 在实务中广泛用于“弱假设、弱参数化”的初级质控, 该比例可根据需要调整, 本次尝试固定在 5/95 以确保可比性. 样本情况见表 26.

在质控样本上, 把“给定质量水平下的 Z 分布”形式化为条件分布.

记第 k 条染色体的主信号为 Z_k , 质量与个体协变量向量为

$$\mathbf{q}_k = (GC_k, \log L, M, N, O, AA, BMI, ZX), \quad (23)$$

则条件分布函数定义为

$$F_{Z_k | \mathbf{q}_k}(z | \mathbf{q}) = \Pr(Z_k \leq z | \mathbf{q}_k = \mathbf{q}). \quad (24)$$

“上尾”指右侧尾部概率 $1 - F_{Z_k | \mathbf{q}_k}(z | \mathbf{q})$. 为在缺乏真阳性的前提下直接控制假阳率, 以条件分位作为判定边界: 对给定 $\alpha \in \{0.99, 0.995\}$, 定义

表 26 样本情况

统计项	内容
总样本	604
严格标签统计(AE+AB)	chr13 阳性=0; chr18 阳性=0; chr21 阳性=0
通过 QC 的样本	501

$$\tau_k^{(a)}(q) = \inf z: F_{Z_k|q_k}(z|q) \geq \alpha, \quad (25)$$

从而有 $\Pr(Z_k \geq \tau_k^{(q)}(q) | q_k = q) = 1 - q$. 量化地说, 当 $q = 0.99$ 或 0.995 时, 分别对应质量水平 q 下期望假阳率约为 1% 或 0.5% . “给定质量水平”指的是具体样本的 q_k 的取值(逐例个体化). 为便于展示与执行, 同时给出 3 组代表性质量水平 $q_k^{(\text{good})}$ 、 $q_k^{(\text{typ})}$ 、 $q_k^{(\text{marg})}$: 对“越大越好”的指标(M , O , $\log L$)分别取较高分位(good)、中位(typ)、较低分位(marg); 对“越小越好”的指标(N , AA)分别取较低分位(good)、中位(typ)、较高分位(marg); GC_k 取居中稳定区间的代表值, BMI 与 ZX 取中位. 三档只是把“连续的个体化规则 $\tau_k^{(a)}(q)$ ”在典型质量截面上离散化表示, 所用变量与风险调整中的 q_k 完全一致; 在逐例判定时亦可直接用该样本的真实 q_k 代入 $\tau_k^{(a)}(q_k)$ 获得个体化阈值.

“临界质量(marg)”指在已通过 QC 的样本里, 按综合质量指数 QI 排名最差的那一档(默认后 20%分位及以下)的样本/质量水平.

三档质量的严格定义与计算: 在通过 QC 的样本上, 先对质量变量作稳健标准化 $z(X) = (X - \text{median}(X))/\text{MAD}(X)$. 定义每条染色体 k 的综合质量指数

$$QI_k = z(M) + z(O) + z(\log L) - z(N) - z(AA) - z(|GC_k - \text{median}(GC_k)|). \quad (26)$$

记 q_{20} 和 q_{80} 为 QI_k 的 20%/80%分位, 则临界质量(marg)为 $QI_k \leq q_{20}$, 典型质量(typ)为 $q_{20} < QI_k < q_{80}$, 良好质量(good)为 $QI_k \geq q_{80}$. 三档的代表点用于表格化阈值: 对“越大越好”的指标($\log L$, M , O)取(marg/typ/good) $\approx$ (20%/50%/85%)分位; 对“越小越好”的指标(N , AA)取(80%/50%/15%)分位; GC_k 取(25%/50%/75%); BMI, ZX 取中位. 将对应的 $q_k^{(\text{marg/typ/good})}$ 代入 $\tau_k^{(q)}(q)$ 得到三档固定阈值行.

“越大越好/越小越好”的判别方向来自测序与统计信号的物理含义: L (总读段)、 M (比对比例)、 O (唯一比对比例)增大意味着有效覆盖与独立信息增多, Z 的方差随之减小, 因而在同等假阳率目标下允许更低的阈值; 相反, N (重复率)与 AA (过滤比例)增大意味着冗余与噪声增加, Z 的不确定性增大, 需要更高的阈值以维持同等尾部概率. 二者不冲突: 它们作用于不同的质量维度, 在条件分布 $F_{Z_k|q_k}$ 中以不同单调方向共同决定上尾厚度.

决策区间:

$$\tau_k^{\text{lo}}(q) = \tau_k^{(0.99)}(q), \tau_k^{\text{hi}}(q) = \tau_k^{(0.995)}(q),$$

则对任一样本的 Z_k 与 q_k , 有以下三段: 1) 阴性区 $Z_k < \tau_k^{\text{lo}}(q_k)$; 2) 观察区 $\tau_k^{\text{lo}}(q_k) \leq Z_k < \tau_k^{\text{hi}}(q_k)$; 3) 阳性区 $Z_k \geq \tau_k^{\text{hi}}(q_k)$.

若采用三档固定展示, 则把 q_k 分别替换为 $q_k^{(\text{good})}$ 、 $q_k^{(\text{typ})}$ 、 $q_k^{(\text{marg})}$, 即得三档对应的“阴性/观察/阳性”区间边界.

为确保边界数值的可用性, 对 $\tau_k^{(q)}$ 做三项一致性约束: 1) 对每一质量档单独以该档内的经验上位设下界锚 $\underline{\tau}_k^{(q)}$, 并取 $\tau_k^{(q)} \leftarrow \max\{\tau_k^{(q)}, \underline{\tau}_k^{(q)}\}$, 避免负阈值与线性外推; 2) 强制 $\tau_k^{\text{hi}}(\cdot) \geq \tau_k^{\text{lo}}(\cdot) + \delta$ ($\delta > 0$), 保证“高特异度线”不低于“低特异度线”; 3) 按质量档序(good $\rightarrow$ typ $\rightarrow$ marg)对 $\tau_k^{\text{lo}}(\cdot)$ 和 $\tau_k^{\text{hi}}(\cdot)$ 分别作保序处理, 使 $\tau_k^{(\cdot)}(\text{good}) \leq \tau_k^{(\cdot)}(\text{typ}) \leq \tau_k^{(\cdot)}(\text{marg})$, 从而刻画“质量越差, 达到同等假阳率所需的阈值越高”的规律. 整体方法在无真阳性样本的情况下, 通过条件分布上尾分位 $\tau_k^{(q)}$ 将“假阳率控制”直接转化为“ Z 判定边界”, 并以同一套 q_k 同时支持个体化阈值与三档固定表示, 阈值分类情况见表 27.

表 27 分类阈值

染色体	分类	z_{lo} ($\approx \text{Sp} \geq 99\%$)	z_{hi} ($\approx \text{Sp} \geq 99.5\%$)	染色体	分类	z_{lo} ($\approx \text{Sp} \geq 99\%$)	z_{hi} ($\approx \text{Sp} \geq 99.5\%$)
chr13	good	2.182	2.409	chr18	marg	5.694	5.975
chr13	typ	2.673	3.682	chr21	good	1.361	3.233
chr13	marg	7.193	8.503	chr21	typ	2.332	3.233
chr18	good	2.871	3.146	chr21	marg	4.668	4.718
chr18	typ	3.071	4.007				

chr13: 在良好质量(good)下, 两个分类阈值 τ^{lo} 和 τ^{hi} 分别为 2.182 和 2.409; 在典型质量(typ)下, 分别为 2.673 和 3.682; 在临界质量(marg)下, 分别为 7.193 和 8.503. 同一分位水平下, 阈值随样本质量由 good、typ 到 marg 逐渐升高, 且 $\tau^{\text{hi}} > \tau^{\text{lo}}$.

chr18: 在良好质量(good)下, 两个分类阈值 τ^{lo} 和 τ^{hi} 分别为 2.871 和 3.146; 在典型质量(typ)下, 分别为 3.071 和 4.007; 在临界质量(marg)下, 分别为 5.694 和 5.975, 变化规律同上.

chr21: 在良好质量(good)下, 两个分类阈值 τ^{lo} 和 τ^{hi} 分别为 1.361 和 3.233; 在典型质量(typ)下, 分别为 2.332 和 3.233; 在临界质量(marg)下, 分别为 4.668 和 4.718. 其中, τ^{hi} 在 good 与 typ 档相同(均为 3.233), 说明这两档的 99.5% 条件上分位非常接近; 随质量变差至 marg 档, 阈值进一步上升.

在仅以 AB 列作为标签(即严格依据 AB 列标注的 chr13、chr18、chr21 非整倍体阳性/阴性结果)的情况下, 本研究采用监督式学习方法(逻辑回归)和 Z-score 确定分类阈值^[15]的方案, 构建女胎异常判定模型. 具体流程如下.

步骤 1 数据基础. 总样本量为 604, 其中 AB 列标签统计显示 chr13 阳性 24 例、chr18 阳性 46 例、chr21 阳性 13 例, 经质控(同“中心 90% 截断”标准: $L \geq Q_{0.05}(L)$, $M \geq Q_{0.05}(M)$, $O \geq Q_{0.05}(O)$, $N \leq Q_{0.95}(N)$, $AA \leq Q_{0.95}(AA)$)后, 通过 QC 的样本共 501 例, 如表 28 所示.

表 28 样本情况

统计项	内容
总样本	604
通过 QC 的样本	501
AB 列标签统计	chr13 阳性=13; chr18 阳性=32; chr21 阳性=10

步骤 2 模型构建. 针对 chr13、chr18、chr21 三条染色体, 分别基于 AB 列标签进行逻辑回归训练, 以染色体 Z 值为主要特征, 结合质量与个体协变量(GC 含量、log L, M, N, O, AA, BMI, ZX), 按目标特异度(99%和 99.5%)估计对应的 Z 阈值(z_{lo} 对应约 99% 特异度, z_{hi} 对应约 99.5% 特异度). 这里选用特异度 $\left(\text{Sp} = \frac{\text{TN}}{\text{TN} + \text{FP}}\right)$ 的原因是, 特异度越高, 假阳性率($\text{FPR} = 1 - \text{Sp}$)越低, 阴性样本误诊为阳性的概率越低, 可以有效地控制假阳性率, 避免误诊.

步骤 3 质量分层阈值. 同非监督方法, 将样本按综合质量指数 QI 分为良好(good)、典型(typ)、临界(marg)三档, 分别计算各档的双阈值. 其中, QI 计算方式为:

$$\text{QI}_k = z(M) + z(O) + z(\log L) - z(N) - z(AA) - z(|\text{GC}_k - \text{median}(\text{GC}_k)|),$$

以 20% 和 80% 分位为界划分三档.

步骤 4 判定逻辑. 对某一质量档位的样本, z 值低于该档低阈值为阴性区; 介于该档高低阈值之间为观察区(建议复检); 高于该档高阈值为阳性区.

chr13 相关表格见表 29 和表 30.

表 29 chr13 分类阈值

分类	$z_{\text{lo}} (\approx \text{Sp} \geq 99\%)$	$z_{\text{hi}} (\approx \text{Sp} \geq 99.5\%)$
good	3.223	3.477
typ	2.896	3.145
marg	2.429	2.671

表 30 chr13 评估指标

指标	TP	TN	FP	FN	sensitivity	specificity
cm_lo	12	484	4	1	0.923	0.992
cm_hi	11	486	2	2	0.846	0.996

这里 cm_lo 是低特异性阈值下的混淆矩阵, cm_hi 是高特异性阈值下的混淆矩阵, 后续表格中的 cm_lo , cm_hi 意义相同.

在 5 折交叉验证下, 模型的 $auc=0.993$.

chr18 相关表格见表 31 和表 32.

表 31 chr18 分类阈值

分类	z_lo ($\approx Sp \geq 99\%$)	z_hi ($\approx Sp \geq 99.5\%$)
good	2.904	3.119
typ	2.721	2.931
marg	2.527	2.732

表 32 chr18 评估指标

指标	TP	TN	FP	FN	sensitivity	specificity
cm_lo	32	465	4	0	1	0.991
cm_hi	31	467	2	1	0.969	0.996

在 5 折交叉验证下, 模型的 $auc=0.999$.

chr21 相关表格见表 33 和表 34.

表 33 chr21 分类阈值

分类	z_lo ($\approx Sp \geq 99\%$)	z_hi ($\approx Sp \geq 99.5\%$)
good	2.298	2.310
typ	2.122	2.133
marg	1.966	1.976

表 34 chr21 评估指标

指标	TP	TN	FP	FN	sensitivity	specificity
cm_lo	10	487	4	0	1	0.992
cm_hi	10	489	2	0	1	0.996

在 5 折交叉验证下, 模型的 $auc=0.995$.

关键规律:

1) 在仅用 AB 列作为标签的实验中, 阈值与质量的关系呈现出随质量从良好到典型(部分涉及临界档)Z 阈值下降的趋势, 这一现象可结合监督式学习对标签的依赖特性解释. 监督式学习直接以 AB 列标注的阳性/阴性结果为目标, 模型学习的是特征(Z 值及质量协变量)与标签的关联. 当样本质量处于良好档时, 测序数据的有效信号更强(如总读段数、唯一比对比例更高, 重复率更低), Z 值对真实异常的区分能力更稳定, 此时模型为准确捕捉 AB 列标注的阳性案例, 需设定相对较高的阈值以减少假阳性——因为高质量数据中 Z 值的微小波动更可能反映真实差异, 过高的阈值可避免将轻微波动误判为异常.

而当质量降至典型档时, 数据中的噪声有所增加, Z 值的稳定性下降. 模型通过学习 AB 列标签发现, 该档中 AB 列标注的阳性案例其 Z 值整体低于良好档, 若沿用良好档的高阈值会导致漏检(即无法匹配 AB 列中的阳性标签). 因此, 为贴合标签分布, 模型会下调阈值, 以在噪声环境中更灵敏地捕捉 AB 列所定义的异常, 此时阈值下降是为了适配该质量档下标签对应的 Z 值实际分布, 确保对 AB 列阳性案例的识别能力, 减少假阴性.

若扩展至临界档, 由于其质量更差, 噪声进一步增大, AB 列标注的阳性案例可能需要更低的 Z

值才能与噪声区分,模型会再次下调阈值,进一步减少假阴性。

2)染色体差异. chr21 的阈值整体低于 chr13 和 chr18,可能与该染色体非整倍体的 Z 值分布特征有关;在模型稳健性上,chr18 模型在 5 折交叉验证下的 $\text{auc}=0.999$,接近完美分类,高于 chr21 (0.995)和 chr13(0.993),说明模型对正负样本的识别稳定性最强,AB 列标签对 chr18 的监督学习效果更稳定.在灵敏度上,chr21 模型最优,漏诊风险为零,两种阈值下灵敏度均为 1.0,能 100%捕获阳性样本. chr13 模型整体弱于 chr18 和 chr21, $\text{auc}=0.993$,为三者最低,灵敏度为 0.923 和 0.846,整体低于 chr18 和 chr21,漏诊率较高。

3)判定应用.通过 AB 列标签训练的模型进行判定时,先计算样本所属的良好、典型或临界质量档,再匹配对应质量档的低特异度判定阈值(约 99% 特异度)和高特异度判定阈值(约 99.5% 特异度).若样本 Z 值低于低特异度判定阈值,则判定为阴性区,提示女胎该染色体非整倍体异常风险较低;若 Z 值介于低、高两个判定阈值之间,则判定为观察区,建议复检以明确情况;若 Z 值高于高特异度判定阈值,则判定为阳性区,提示异常风险较高,需进一步检查.未通过 QC 的样本建议重测,保障结果的可靠性。

3 评阅情况与参赛论文的主要问题

根据前述的解答步骤,对 2025 年参赛队伍提交的报告进行了评阅.对于问题 1 的解答,参赛队伍能意识到该问题不能只直接利用线性的 Pearson 相关系数,还使用了 Spearman 相关系数等非线相关度量,少部分队伍很好地利用随机效应或分组机制来衡量相关关系,答题情况普遍较为完整.但是,大部分队伍直接利用多元线性回归模型对复杂数据进行线性拟合,难以找到胎儿浓度随时间变化的真正趋势,同时也缺乏良好的可解释性。

由于问题 2 和问题 3 之间的递进关系,这两题的解答均需根据考虑孕周对 BMI 有序区间分组的差异性 or 浓度超过 4% 的概率差异来划分 BMI 区间,并融合达标概率和孕妇潜在风险来确定每组的最佳 NIPT 检测时点.少部分参赛队伍给出了分组的差异性指标及优化目标函数,并以此来确定 BMI 分组和最优检测时点,得到的结果与实际经验相符合.需要指出的是,超半数队伍选择 K -means、层次聚类等经典方法直接对 BMI 数据进行聚类,未考虑协变量孕周变化对 BMI 有序分组的影响,以及分组的差异性建模,这样的解答被判为一般.对于问题 4,参赛队伍多选择机器学习算法 XGBoost、逻辑回归等对女胎染色体异常数据进行分类建模,忽略了异常判断与普通分类的区别,绝大多数队伍在此题上的完成效果并不理想,未能给出合理的且具有可操作性的判定方案。

综合来看,大部分参赛队伍在建模过程中表现出较好的基础能力,逻辑性与统计意识相比以往有所提升.有少数队伍对各问题均选择深度学习算法直接建模,仍存在“数据变动、方法固化”的现象,需加强根据不同数据特点灵活选择合适处理方法的能力,提高模型的适应性和可解释性。

参考文献

- [1]全国大学生数学建模竞赛组委会. 2025 年“高教社杯”全国大学生数学建模竞赛赛题[Z/OL]. [2025-09-04]. https://www.mcm.edu.cn/html_cn/node/03c91a444e62eee81a3740fa97a461a6.html.
- [2]Laird N M, Ware J H. Random-effects models for longitudinal data[J]. Biometrics, 1982: 963-974.
- [3]Zhang H, Hung C S, Lin C H R, et al. Predicting fetal growth with curve fitting and machine learning[J]. Bioengineering, 2025, 12(7): 730.
- [4]Hallac D, Nystrup P, Boyd S. Greedy Gaussian segmentation of multivariate time series[J]. Advances in Data Analysis and Classification, 2019, 13(3): 727-751.
- [5]Chen Y T, Chiou J M, Huang T M. Greedy segmentation for a functional data sequence[J]. Journal of the American Statistical Association, 2023, 118(542): 959-971.
- [6]Cox D R. Regression models and life-tables[J]. Journal of the Royal Statistical Society: Series B(Methodological), 1972, 34(2): 187-202.
- [7]Cockeran M, Meintanis S G, Allison J S. Goodness-of-fit tests in the Cox proportional hazards model[J].

- Communications in Statistics-Simulation and Computation, 2021, 50(12): 4132-4143.
- [8] Stock S J, Horne M, Bruijn M, et al. Development and validation of a risk prediction model of preterm birth for women with preterm labour symptoms (the QUIDS study): A prospective cohort study and individual participant data meta-analysis[J]. PLoS Medicine, 2021, 18(7): e1003686.
- [9] Bokulich N A, Subramanian S, Faith J J, et al. Quality-filtering vastly improves diversity estimates from illumina amplicon sequencing[J]. Nature methods, 2013, 10(1): 57-59.
- [10] Bates M D, Castellano K E, Rabe-Hesketh S, et al. Handling correlations between covariates and random slopes in multilevel models[J]. Journal of Educational and Behavioral Statistics, 2014, 39(6): 524-549.
- [11] McPhee R D, Seibold D R. Rationale, procedures, and applications for decomposition of explained variance in multiple regression analyses[J]. Communication Research, 1979, 6(3): 345-384.
- [12] Koenker R, Bassett Jr G. Regression quantiles[J]. Econometrica: Journal of the Econometric Society, 1978: 33-50.
- [13] Jewell W S. A linear risk model[J]. Journal of the Operational Research Society, 1961, 12(4): 209-220.
- [14] Xu Y, Jiang H, Ma L, et al. An effective algorithm for noise variance estimation in shearlet domain[C]//Eighth International Conference on Digital Image Processing (ICDIP 2016). SPIE, 2016, 10033: 336-341.
- [15] Zhou L, Zhang B, Liu J, et al. The optimal cutoff value of Z-scores enhances the judgment accuracy of noninvasive prenatal screening[J]. Frontiers in Genetics, 2021, 12: 690063.

Review of the "Timing Selection for NIPT and Fetal Abnormality Determination"

LAI Xin¹, WANG Jiayin¹, XIN Shiji¹, CUI Hengjian²

(1. School of Computer Science and Technology, Xi'an Jiaotong University, Xi'an, Shaanxi 710049, China;

2. School of Mathematical Sciences, Capital Normal University, Beijing 100048, China)

Abstract: This article provides a brief review of "Timing Selection for NIPT and Fetal Abnormality Determination", Problem C of the CUMCM 2025. It introduces the overview of the problem and solution methods, presents the algorithms and results for solving the problem, and lists the main issues existing in the participating papers.

Key words: statistical regression; greedy partitioning; quantile regression; supervised learning

作者简介

赖欣(1981—),男,博士,副教授,主要研究方向为生物统计、医疗数据分析、生物信息计算与数字健康.

王嘉寅(1986—),男,博士,教授,主要研究方向为生物信息学与生物信息管理、工程与复杂运营管理、生物信息的监管与审评技术、生物信息计算与数字健康.

辛世纪(2001—),男,西安交通大学硕士生,主要研究方向为医疗数据挖掘.

崔恒建(1963—),男,博士,教授,主要研究方向为数理统计和稳健统计理论和方法、大数据统计、金融统计与质量管理.

(责任编辑:梁向前)